

# GUÍA Y PLANTILLA PARA ENTREGA DE TRABAJO FINAL DE GRADO DE LA USFQ

## APLICA PARA: ESTUDIANTES DE CARRERAS DE PREGRADO

1. El producto para entregar, de la materia final de carrera, puede corresponder a:
  - Un trabajo final o reporte escrito; o,
  - Una presentación o producción artística abierta al público (carreras relacionadas con artes) que deberá incluir una reflexión teórica escrita cumpliendo los parámetros básicos de esta guía.
2. Se debe priorizar la calidad del trabajo final, no su extensión. Calidad no es cantidad. Por esta razón, la extensión del trabajo final o de la reflexión teórica escrita será ajustada por el profesor del curso correspondiente, para garantizar que el estudiante pueda culminarlo dentro del periodo en que está registrado en la materia. Se recomienda:
  - No superar las 30 páginas de extensión (sin contar páginas preliminares, referencias ni anexos) en el caso del trabajo final o reporte escrito.
  - No superar las 10 páginas de extensión (sin contar páginas preliminares, referencias ni anexos) en el caso de la reflexión teórica escrita sobre la presentación o producción artística.
3. Se debe utilizar un estilo específico (APA, MLA, Chicago, entre otros).

En ciertos Colegios Académicos, como el de Jurisprudencia, existen guías específicas para formato y estilo. El estudiante debe consultar con su Decanato para determinar el formato que corresponde.

4. Para identificar los niveles de los diferentes títulos, sugiere utilizar el siguiente formato:

### Sugerencia USFQ para niveles de títulos

|         |                                                                                                                                                                 |
|---------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Nivel 1 | <b>CENTRADO, EN NEGRILLA, TODAS LAS PALABRAS EN MAYÚSCULAS, tamaño de letra 12 puntos</b>                                                                       |
| Nivel 2 | <b>Alineado a la izquierda, en negrilla, mayúscula solo la primera letra de la primera palabra, tamaño de letra 12 puntos</b>                                   |
| Nivel 3 | <b>Con sangría de párrafo, negrilla, mayúscula solo la primera letra de la primera palabra, tamaño de letra 12 puntos y terminado en punto.</b>                 |
| Nivel 4 | <b><i>Con sangría de párrafo, negrilla, cursiva, mayúscula solo la primera letra de la primera palabra, tamaño de letra 12 puntos y terminado en punto.</i></b> |
| Nivel 5 | <b><i>Con sangría de párrafo, cursiva, mayúscula solo la primera letra de la primera palabra, tamaño de letra 12 puntos y terminado en punto.</i></b>           |

5. Tipo de letra: Times New Roman, Arial o Calibri.
6. Los otros textos del trabajo que no sean títulos deben tener un tamaño de letra de 12 puntos, sin negrita.
7. Utilizar el Formato de hoja A4.
8. Escribir el texto a doble espacio.
9. Las páginas del trabajo final deben ir numeradas en la parte superior derecha, excepto la portada.

Los estudiantes son los responsables directos de verificar que todo el material que utilizan en su trabajo final, en especial tablas y figuras, pueden ser usados y reproducidos. Material que tenga derechos de autor reservados no deberá ser incluido en este trabajo a menos que el estudiante cuente con el permiso explícito de sus autores (con excepción de citas y paráfrasis, las cuales deben ser siempre acreditadas a su autor).

La redacción debe ser escrita en lenguaje académico y las fuentes deben ser citadas siguiendo el formato escogido, tanto para citas en el texto como para las Referencias Bibliográficas.

# CONTENIDOS DEL TRABAJO FINAL O REPORTE ESCRITO\*

| CONTENIDO                        | ESPECIFICACIÓN                                                                                                                                                                                                   |
|----------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>PORTADA</b>                   | Elaborado en una hoja separada. Sin numeración. Ver formato a continuación.                                                                                                                                      |
| <b>HOJA DE CALIFICACIÓN</b>      | Elaborado en una hoja separada. Ver formato a continuación.                                                                                                                                                      |
| <b>HOJA DE DERECHOS DE AUTOR</b> | Elaborado en una hoja separada. Ver formato a continuación.                                                                                                                                                      |
| <b>RESUMEN</b>                   | Elaborado en una hoja separada.                                                                                                                                                                                  |
| <b>PALABRAS CLAVE</b>            | Deben ser listadas, separadas por comas, luego del resumen.                                                                                                                                                      |
| <b>ABSTRACT</b>                  | Elaborado en una hoja separada. Corresponde a la traducción al inglés del resumen.                                                                                                                               |
| <b>KEY WORDS</b>                 | Corresponde a la traducción al inglés del listado de palabras clave. Deben ser listadas, separadas por comas, luego del abstract.                                                                                |
| <b>TABLA DE CONTENIDOS</b>       | Elaborado en una hoja separada. Corresponde al índice del trabajo y debe incluir sus títulos, subtítulos, y números de página asociados.                                                                         |
| <b>ÍNDICE DE TABLAS</b>          | Debe incluir el listado de tablas detalladas en el trabajo y números de página asociados, cuando aplique.                                                                                                        |
| <b>ÍNDICE DE FIGURAS</b>         | Debe incluir el listado de figuras detalladas en el trabajo y números de página asociados, cuando aplique.                                                                                                       |
| <b>CUERPO DEL DOCUMENTO</b>      | Corresponde al desarrollo del trabajo. Debe incluir: <ol style="list-style-type: none"> <li>1. Introducción.</li> <li>2. Desarrollo (todas las secciones que correspondan).</li> <li>3. Conclusiones.</li> </ol> |
| <b>REFERENCIAS</b>               | Corresponde al listado de referencias utilizadas para el desarrollo del trabajo, elaborado conforme el estilo utilizado (APA, MLA, otros).                                                                       |
| <b>ANEXOS</b>                    | Corresponde al detalle de anexos del trabajo, cuando aplique.                                                                                                                                                    |

\*Las carreras de producción audiovisual del COCOA (Animación Digital, Cine y Producción para Medios de Comunicación) tienen sus propias especificidades en cuanto al documento del trabajo final que los estudiantes deben entregar en Biblioteca USFQ. En estas carreras, se espera que el estudiante entregue el producto audiovisual desarrollado durante la materia final de la carrera, así como un reporte escrito que debe cumplir con las siguientes características:

- **Animación Digital**

Entregar la biblia de producción del proyecto correspondiente. El cuerpo del documento debe incluir la introducción, la ficha técnica, el desarrollo (preproducción, producción y postproducción), y las conclusiones. En la sección de conclusiones el estudiante deberá generar un diseño y una diagramación propia acorde a su proyecto. En dicho diseño, la tipografía, fondo, color, disposición del texto, e imágenes quedan a libre elección del estudiante. Para todas las demás secciones se deben seguir las instrucciones detalladas en esta guía. Es necesario incluir una tabla de contenidos.

- **Cine**

Para un proyecto de cortometraje, el cuerpo del documento corresponde al libro de producción.

Para un proyecto de colaboración técnica, el cuerpo del documento corresponde al diario de trabajo, la propuesta y los referentes utilizados.

Para un proyecto de largometraje el cuerpo del documento corresponde al proceso de investigación y los referentes utilizados.

Para un proyecto de guion de largometraje el documento es una reflexión corta del proceso de elaboración y el detalle del guion.

En todos estos casos, el cuerpo del documento puede tener sus propios formatos, pero deberá estar precedido por una introducción, desarrollo y bibliografía que deberán ajustarse a las instrucciones detalladas en esta guía. Los anexos pueden contener una documentación de los procesos de producción del proyecto que suelen tener formatos más diversos.

- **Producción para Medios de Comunicación**

El cuerpo del documento corresponde al libro de producción del proyecto audiovisual desarrollado (por ejemplo: un cortometraje, un proyecto de una serie, un documental, etc.). El cuerpo del documento puede tener su propio formato, pero deberá estar precedido por una introducción, desarrollo (objetivos, justificación, marco teórico, etc.) y bibliografía que deberán ajustarse a las instrucciones detalladas en esta guía. Los anexos pueden contener una documentación de los procesos de producción del proyecto que suelen tener formatos variados.

- **Artes Visuales**

El documento deberá contener una reflexión escrita acerca del proceso de producción de la obra artística o de la colección de moda, con una introducción, desarrollo y bibliografía que deberán ajustarse a las instrucciones detalladas en esta guía. Los anexos pueden contener una documentación o recopilación gráfica de los procesos de producción de la obra artística o de la colección de moda a ser exhibida y suelen tener formatos variados.

- **Diseño Gráfico, Comunicación, Publicidad y Periodismo**

El documento deberá contener una reflexión escrita del proyecto final, con una introducción, desarrollo y bibliografía que deberán ajustarse a las instrucciones detalladas en esta guía. Los anexos pueden contener una documentación o recopilación gráfica o digital de los procesos de producción del proyecto final y suelen tener formatos variados.

## **CONTENIDOS DE LA REFLEXIÓN TEÓRICA ESCRITA\***

\*Para trabajos finales que involucren una presentación o producción artística (aplica únicamente para carreras relacionadas con artes)

| <b>CONTENIDO</b>                 | <b>ESPECIFICACIÓN</b>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
|----------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>PORTADA</b>                   | Elaborado en una hoja separada. Sin numeración. Ver formato a continuación.                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
| <b>HOJA DE CALIFICACIÓN</b>      | Elaborado en una hoja separada. Ver formato a continuación.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
| <b>HOJA DE DERECHOS DE AUTOR</b> | Elaborado en una hoja separada. Ver formato a continuación.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
| <b>RESUMEN</b>                   | Elaborado en una hoja separada.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
| <b>PALABRAS CLAVE</b>            | Deben ser listadas, separadas por comas, luego del resumen.                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       |
| <b>ABSTRACT</b>                  | Elaborado en una hoja separada. Corresponde a la traducción al inglés del resumen.                                                                                                                                                                                                                                                                                                                                                                                                                                                                |
| <b>KEY WORDS</b>                 | Corresponde a la traducción al inglés del listado de palabras clave. Deben ser listadas, separadas por comas, luego del abstract.                                                                                                                                                                                                                                                                                                                                                                                                                 |
| <b>CUERPO DEL DOCUMENTO</b>      | Corresponde al desarrollo del trabajo. Debe incluir: <ol style="list-style-type: none"><li>1. Introducción.</li><li>2. Reflexión teórica.</li><li>3. Conclusiones de la experiencia práctica</li></ol>                                                                                                                                                                                                                                                                                                                                            |
| <b>REFERENCIAS</b>               | Corresponde al listado de referencias utilizadas para el desarrollo del trabajo, elaborado conforme el estilo utilizado (APA, MLA, otros).                                                                                                                                                                                                                                                                                                                                                                                                        |
| <b>ANEXOS</b>                    | En los anexos es obligatorio incluir fotos del evento y detallar su fecha, lugar de ocurrencia y cantidad de participantes/ asistentes. También se debe incluir la evidencia de invitaciones o convocatorias al evento, fotos del público asistente, fotos del proceso de preparación de la presentación o producción artística, y cualquier otro elemento que proporcione evidencia del proceso de creación. Adicionalmente, se recomienda grabar la presentación o producción y proporcionar en esta sección en link de acceso a este material. |

**A PARTIR DE LA SIGUIENTE HOJA, SE ENCUENTRA UNA PLANTILLA EN LA QUE SE PUEDE REEMPLAZAR EL TEXTO EN ROJO CON LA INFORMACIÓN PARA PRESENTAR EL TRABAJO FINAL.** Para ello, se debe considerar los requerimientos de información presentados anteriormente.

En las hojas de portada, calificación, de derechos de autor y referencias todos los textos en rojo deben ser reemplazados por los datos particulares y cambiados a negro antes de entregar el trabajo.

**UNIVERSIDAD SAN FRANCISCO DE QUITO USFQ**

**Colegio de Ciencias e Ingenierías**

**Arquitectura Mixture of Experts para Clasificación de Ataques  
en Dataset con Desbalance Extremo de Clases**

**John Kléber Ochoa Abad**

**Ingeniería en Ciencias de la Computación**

Trabajo de fin de carrera presentado como requisito  
para la obtención del título de  
Ingeniero en Ciencias de la Computación

Quito, 08 de mayo de 2026

**UNIVERSIDAD SAN FRANCISCO DE QUITO USFQ**

**Colegio de Ciencias e Ingenierías**

**HOJA DE CALIFICACIÓN  
DE TRABAJO DE FIN DE CARRERA**

**Arquitectura Mixture of Experts para Clasificación de Ataques  
en Dataset con Desbalance Extremo de Clases**

**John Kléber Ochoa Abad**

**Nombre del profesor, Título académico**

**Ricardo Flores Moyano, PhD.**

Quito, 08 de mayo de 2026

## © DERECHOS DE AUTOR

Por medio del presente documento certifico que he leído todas las Políticas y Manuales de la Universidad San Francisco de Quito USFQ, incluyendo la Política de Propiedad Intelectual USFQ, y estoy de acuerdo con su contenido, por lo que los derechos de propiedad intelectual del presente trabajo quedan sujetos a lo dispuesto en esas Políticas.

Asimismo, autorizo a la USFQ para que realice la digitalización y publicación de este trabajo en el repositorio virtual, de conformidad a lo dispuesto en la Ley Orgánica de Educación Superior del Ecuador.

Nombres y apellidos: John Kléber Ochoa Abad

Código: 00345743

Cédula de identidad: 1719948216

Lugar y fecha: Quito, 04 de mayo de 2026

## **ACLARACIÓN PARA PUBLICACIÓN**

**Nota:** El presente trabajo, en su totalidad o cualquiera de sus partes, no debe ser considerado como una publicación, incluso a pesar de estar disponible sin restricciones a través de un repositorio institucional. Esta declaración se alinea con las prácticas y recomendaciones presentadas por el Committee on Publication Ethics COPE descritas por Barbour et al. (2017) Discussion document on best practice for issues around theses publishing, disponible en <http://bit.ly/COPETheses>.

## **UNPUBLISHED DOCUMENT**

**Note:** The following capstone project is available through Universidad San Francisco de Quito USFQ institutional repository. Nonetheless, this project – in whole or in part – should not be considered a publication. This statement follows the recommendations presented by the Committee on Publication Ethics COPE described by Barbour et al. (2017) Discussion document on best practice for issues around theses publishing available on <http://bit.ly/COPETheses>.



## Resumen

El presente trabajo aborda la implementación de una arquitectura de Inteligencia Artificial basada en Mixture of Experts (MoE) para la detección y clasificación de intrusiones en ciberseguridad, un problema crítico en la protección de infraestructuras y sistemas. Utilizando el dataset CIC-IDS2017, se enfrentó el desafío del desbalance extremo de clases, preservando la distribución estructural original con el fin de evitar la introducción de sesgos. La evaluación inicial, basada en el F1-score macro, evidenció que los modelos basados en árboles de decisión, como Random Forest (0.85) y XGBoost (0.83), superan a las redes neuronales estándar de tipo Perceptrón Multicapa (0.77) en la identificación de patrones. A partir de estos resultados, se determinó que la ponderación de clases mediante funciones de costo resulta más efectiva que técnicas como el sobremuestreo o la selección de características para mejorar el rendimiento de los modelos base. Con el objetivo de superar estos resultados, se seleccionó Random Forest como modelo base y se desarrollaron arquitecturas MoE incrementales, evolucionando hacia la integración de modelos homogéneos para expertos de tipo Red Neuronal TabTransformer. Los experimentos con MoEs demostraron que el uso de soft gating es superior al hard gating, ya que permite una combinación ponderada de expertos permitiendo capturar relaciones complejas mediante mecanismos de autoatención. Asimismo, se evidenció que la aplicación de tasas de aprendizaje independientes durante el proceso de fine-tuning es clave para lograr una adecuada sincronización del ensamble. Finalmente, el modelo MoE propuesto superó a los clasificadores tradicionales, alcanzando un F1-score macro de 0.89 y una precisión macro de 0.96. Estos resultados sugieren que la segmentación taxonómica de expertos y el enrutamiento continuo constituyen un enfoque efectivo y prometedor para el desarrollo de soluciones avanzadas de ciberseguridad orientadas a la protección de sistemas críticos mediante la distinción correcta de intrusiones respecto a tráfico benigno.

**Palabras clave:** “Mixture of Experts”, Inteligencia Artificial, Ciberseguridad, Ponderación por clases, Desbalance de clases, Sobremuestreo, Selección de Características, Funciones de Pérdida, Sistemas de detección de intrusiones, Redes Neuronales, “Random Forests”, “XGBoost”, “Tuning”

## Abstract

This work addresses the implementation of Artificial Intelligence architecture based on Mixture of Experts (MoE) for the detection and classification of intrusions in cybersecurity, a critical problem in the protection of infrastructures and systems. Using the CIC-IDS2017 dataset, the challenge of extreme class imbalance was faced, preserving the original structural distribution to avoid the introduction of biases. The initial evaluation, based on the F1-score macro, showed that models based on decision trees, such as Random Forest (0.85) and XGBoost (0.83), outperform standard Multilayer Perceptron neural networks (0.77) in pattern identification. From these results, it was determined that class weighting using cost functions is more effective than techniques such as oversampling or feature selection to improve the performance of base models. To overcome these results, Random Forest was selected as the base model and incremental MoE architectures were developed, evolving towards the integration of homogeneous models for experts of the TabTransformer Neural Network type. The experiments with MoEs showed that the use of soft gating is superior to hard gating, since it allows a weighted combination of experts allowing complex relationships to be captured through self-attention mechanisms. Likewise, it was evidenced that the application of independent learning rates during the fine-tuning process is key to achieve adequate assembly synchronization. Finally, the proposed MoE model outperformed traditional classifiers, achieving an F1-macro score of 0.89 and a macro accuracy of 0.96. These results suggest that taxonomic segmentation of experts and continuous routing constitute an effective and promising approach for the development of advanced cybersecurity solutions aimed at protecting critical systems through the correct distinction of intrusions from benign traffic.

**Keywords:** Mixture of Experts, Artificial Intelligence, Cybersecurity, Class weighting, Class imbalance, Oversampling, Feature Selection, Loss functions, Intrusion detection systems, Neural Networks, Random Forests, XGBoost, Tuning

## Tabla de Contenido

|                                                                                                                                       |    |
|---------------------------------------------------------------------------------------------------------------------------------------|----|
| Introducción .....                                                                                                                    | 12 |
| Estado del Arte.....                                                                                                                  | 13 |
| Desarrollo: Primera Parte: Data Engineering .....                                                                                     | 14 |
| Desarrollo: Segunda Parte: Modelos Base.....                                                                                          | 20 |
| Desarrollo: Tercera Parte: Mixture of Experts.....                                                                                    | 34 |
| Desarrollo: Cuarta Parte: Análisis de Resultados .....                                                                                | 46 |
| Conclusiones .....                                                                                                                    | 51 |
| Trabajo Futuro .....                                                                                                                  | 55 |
| Referencias bibliográficas.....                                                                                                       | 57 |
| Anexo A: Conteo Inicial de Muestras por Clase .....                                                                                   | 59 |
| Anexo B: Gráficos de Distribución de Features para tráfico Benigno y Ataques .....                                                    | 60 |
| Anexo C: Boxplots de Features por Clase para Flujos Benignos e Intrusiones.....                                                       | 64 |
| Anexo D: Tabla de Resumen Antes de la Limpieza de Datos .....                                                                         | 67 |
| Anexo E: Tabla de Resumen Después de la Limpieza de Datos .....                                                                       | 68 |
| Anexo F: Distribuciones por característica antes y después de imputaciones por regresores bayesianos y de tipo árbol de decisión..... | 69 |

## Índice de Tablas

|                                                                                                                             |    |
|-----------------------------------------------------------------------------------------------------------------------------|----|
| Tabla 1. Distribuciones antes y después de la limpieza de datos.....                                                        | 19 |
| Tabla 2. Métricas de Mejores Modelos Random Forest por experimento.....                                                     | 30 |
| Tabla 3. Métricas de Mejores Modelos XGBoost por experimento .....                                                          | 31 |
| Tabla 4. Métricas de Mejores Modelos Red Neuronal de tipo Perceptrón Multicapa por experimento.....                         | 32 |
| Tabla 5. Métricas de Mejores Modelos MoE por arquitectura y sobremuestreo en subconjuntos de entrenamiento de expertos..... | 46 |

## Índice de Figuras

|                                                                                         |    |
|-----------------------------------------------------------------------------------------|----|
| Figura 1. Distribución de Clases en Dataset de Intrusiones.....                         | 15 |
| Figura 2. Matriz de correlación para características del Dataset de Intrusiones.....    | 16 |
| Figura 3. Pipeline para Limpieza de Dataset de Intrusiones.....                         | 20 |
| Figura 4. Pipeline para Generación de Modelos Base de Clasificación de Intrusiones..... | 22 |
| Figura 5. Arquitectura MoE “Hard Gating” Top-K con expertos Perceptrón Multicapa.....   | 39 |
| Figura 6.Arquitectura MoE “Soft Gating” con expertos Perceptrón Multicapa .....         | 42 |
| Figura 7. Arquitectura MoE “Soft Gating” con expertos TabTransformer .....              | 44 |

## Introducción

El presente trabajo de fin de carrera consiste en el diseño, implementación y evaluación de una arquitectura de Inteligencia Artificial basada en Mixture of Experts para la detección y clasificación de intrusiones en sistemas de ciberseguridad. El tema surge de una cuestión clara: en situaciones reales, el tráfico de red benigno es inmensamente mayor que el malicioso. Este desbalance estadístico provoca que los modelos tradicionales se sesguen hacia la mayoría y fallen al detectar los ataques menos frecuentes [1]. Para mitigar este problema en etapas tempranas, la ingeniería de datos integra técnicas de preprocesamiento, tales como la generación de datos sintéticos [2]. Sin embargo, dado que estas estrategias a nivel de datos suelen ser insuficientes ante escenarios de desbalance extremo, el proyecto busca abordar el problema directamente desde la ingeniería del modelo. Se plantea una propuesta basada en una arquitectura Mixture of Experts que tenga el uso de múltiples expertos y un sistema de compuerta enfocado en potenciar el entrenamiento sobre clases minoritarias. Para validar el aporte real de esta propuesta, su desempeño se contrastará frente a modelos base tradicionales utilizando métricas robustas al desbalance, como el Recall por clase y el F1-Score macro para evidenciar la ganancia predictiva [3]. Este proyecto resulta fundamental en el contexto ecuatoriano y global, debido a que la acelerada digitalización incrementa cada día la exposición a ciberataques. Por ello, contar con modelos precisos de detección y prevención que protejan la infraestructura de un sistema y detecten amenazas inusuales sin dejarse sesgar por el tráfico normal, es una necesidad imperativa. Las siguientes secciones del documento detallarán la ingeniería de datos, la evaluación de los modelos base, la implementación técnica de arquitecturas Mixture of Experts y el análisis de los resultados obtenidos. A continuación, se inicia presentando el estado del arte para justificar las decisiones de diseño y destacar los aportes de este proyecto frente a otras alternativas actuales.



## Estado del Arte

La detección y clasificación de intrusiones en sistemas de ciberseguridad mediante Inteligencia Artificial se abordó inicialmente mediante modelos tradicionales como Support Vector Machine, Random Forest, XGBoost. Si bien estos enfoques logran resultados aceptables, presentan limitaciones de generalización y escalabilidad [4]. Para superar esto, la investigación reciente ha mirado hacia el Deep Learning al emplear redes neuronales tipo MLP y de tipo convolucional [5]. Aunque con esto logran mejoras notables, estos modelos activan todos sus parámetros en cada inferencia, elevando el costo computacional, y siguen siendo sensibles a clases poco representadas. Frente a esto, el proyecto busca aportar una arquitectura que delega la decisión a expertos condicionados a los inputs, reduciendo el cómputo innecesario. A la par, la literatura actual suele abordar el desbalance extremo en un dataset de intrusiones mediante técnicas a nivel de datos como el sobremuestreo [6]. Aunque estas estrategias son beneficiosas, el aprendizaje del modelo sigue siendo global por lo que el modelo propuesto busca llenar este vacío mediante una arquitectura basada en que distintos expertos aprendan patrones de las clases minoritarias, sin depender de la manipulación previa de los datos. Esto se busca lograr mediante el paradigma Mixture of Experts, el cual ha sido validado en áreas como visión por computador y procesamiento de lenguaje natural, donde su principal ventaja es escalar la capacidad predictiva en escenarios de desbalance [7]. Y en el dominio de la detección de intrusiones, el estudio de Ilias et al. [8] representa uno de los primeros esfuerzos en emplear dicho paradigma Mixture of Experts para clasificar tráfico en redes. En dicha investigación, se demostró superioridad frente a clasificadores estándar, pero identificaron que el mecanismo de compuerta favorecía a las clases mayoritarias. Este proyecto extiende directamente esa línea de investigación, proponiendo una arquitectura diseñada para el desbalance extremo, con el objetivo de garantizar la detección de ataques raros y favorecer una generalización real.

## Desarrollo: Primera Parte: Data Engineering

- **Dataset:**

En la fase inicial del proyecto, se seleccionó el conjunto de datos "Intrusion Detection Evaluation Dataset (CIC-IDS2017)", elaborado por la Universidad de New Brunswick [9]. Este dataset incluye muestras de tráfico benigno y múltiples clases de ataques con datos extraídos de flujos de red mediante la herramienta "Cicflowmeter". Los datos abarcan diversos protocolos de comunicación como HTTP, HTTPS, FTP, SSH y protocolos de correo electrónico a la vez que contienen datos de diferentes tipos de intrusiones como DDoS, Bot, Ataques Web, entre otros. Cabe destacar, que este tráfico fue capturado a partir de una topología de red realista que integra módems, firewalls, switches, routers y servidores operando bajo sistemas operativos heterogéneos [9]. Para la implementación de este proyecto, los archivos CSV correspondientes se descargaron y consolidaron en un Dataframe, estableciendo así la base operativa para la etapa de preprocesamiento y limpieza de datos, paso previo para el entrenamiento tanto de los modelos base como de la arquitectura Mixture of Experts.

- **Caracterización del Dataset**

Como parte de la caracterización de los datos se identificaron los siguientes atributos:

- **Cantidad de Muestras:** 2830743
- **Cantidad de Features:** 78 con características primordiales para caracterizar tráfico como: flujo de bytes/s, flujo de paquetes/s, puerto de destino, duración del flujo, etc.
- **Cantidad de Labels:** 15 incluyendo la clase de tráfico benigno y 14 variaciones de intrusiones en sistemas de ciberseguridad

A la par, se buscó entender la distribución de las clases a lo largo de las muestras lo cual se muestra en la siguiente figura en la que evidentemente se observa el desbalance de clases:




Figura 1. Distribución de Clases en Dataset de Intrusiones

Con base en dicha distribución, se buscó identificar el nivel de desbalance para lo cual se identificó que el 80,3% es tráfico benigno mientras que 19,7% corresponde a muestras de ataques de diferente tipo. A su vez, el ratio de desbalance corresponde a 206645.18 mientras que la entropía normalizada es de 0.2837 lo cual indica el desbalance extremo de clases. De igual forma, para entender con mayor detalle la cantidad de muestras por clase se puede verificar la tabla de conteo inicial de muestras por clase (Ver Anexo A) y gráficos de distribuciones y boxplots de características principales para caracterización de flujos de datos entre tráfico benigno e intrusiones (Ver Anexos B y C). Dicho análisis se fundamentó sobre la idea de encontrar características que en primera instancia permitan diferenciar el tráfico benigno de las intrusiones. La exploración de datos reveló que ciertas características permiten diferenciar claramente el tráfico benigno de las intrusiones. Variables relacionadas con la longitud de los paquetes y los intervalos de tiempo entre paquetes, como la varianza de la longitud de los paquetes (16.23) y la desviación estándar del tiempo entre paquetes enviados (8.21), presentan diferencias significativas entre ambos tipos de tráfico. Medidas de inactividad

como el tiempo mínimo, promedio y máximo de inactividad muestran patrones distintos, con valores de percentil 95 cercanos a  $8.83 \times 10^7$ . Además, el máximo del tiempo entre paquetes del flujo, el máximo del tiempo entre paquetes enviados y el tamaño promedio de los paquetes destacan por su alta correlación e información mutua, mientras que características como las banderas urgentes de los paquetes y la longitud de los encabezados de los paquetes de regreso resultan poco relevantes. Estos hallazgos proporcionan criterios sólidos para seleccionar las variables más discriminativas en modelos de clasificación de intrusiones. Por último, a continuación, se agrega un gráfico de la correlación entre características el cual es importante para reconocer de forma visual cuanto aportan las características a la distinción de flujos.



Figura 2. Matriz de correlación para características del Dataset de Intrusiones

- **Limpieza del Dataset**

El proceso de limpieza siguió buenas prácticas en detección de intrusiones, preservando la distribución original de las clases y eliminando inconsistencias. Para describir la estructura y calidad del Dataset previo al proceso de limpieza, se presenta una tabla resumen con estadísticas generales en el Anexo D.

1. Eliminación de columnas inconsistentes: Siguiendo las recomendaciones para la depuración de datos de tráfico de red [10], se identificaron variables con valores sin interpretación física válida, como magnitudes negativas. Se estableció como criterio formal de eliminación la presencia de valores inconsistentes en una proporción superior al 30% de las observaciones, dado que en estos casos la corrección individual puede introducir mayor sesgo que la exclusión de la variable [11]. Bajo este criterio, las columnas “Bytes de ventana inicial hacia atrás” y “Bytes de ventana inicial hacia adelante” fueron eliminadas. Asimismo, se descartó la característica duplicada “Longitud de cabecera hacia adelante”.
2. Tratamiento de valores negativos remanentes: Para las columnas restantes con valores negativos se aplicó un criterio diferenciado según su distribución por clase. Ocho columnas presentaban valores negativos exclusivamente en la clase mayoritaria. En estos casos, se optó por la eliminación puntual de dichas instancias al representar menos del 0.007% de la clase, umbral estadísticamente despreciable ( $<0.01\%$ ) [12].
3. Manejo de valores nulos iniciales: Se eliminaron 2,990 registros pertenecientes a la clase mayoritaria que contenían valores nulos estructurales. Como criterio de decisión se estableció que la eliminación sería aceptable si la variación máxima en proporciones de clase fuese inferior al 1%. La diferencia máxima observada fue de  $2.08 \times 10^{-4}$ , por lo que se consideró que la distribución no fue alterada significativamente [12]. Los valores nulos restantes se reservaron para imputación supervisada.

4. Eliminación de duplicados: En concordancia con la literatura sobre aprendizaje en escenarios desbalanceados [10], [13], se eliminaron registros duplicados exclusivamente en la clase mayoritaria. El criterio aplicado consistió en preservar íntegramente las clases minoritarias para evitar pérdida de información representativa, dado que la eliminación indiscriminada de duplicados puede incrementar artificialmente el desbalance relativo.
5. Eliminación de características constantes: Se identificaron ocho columnas con varianza nula (valor constante igual a cero). Conforme al criterio formal de selección de características, variables con varianza cero no aportan capacidad discriminativa ni información útil para modelos supervisados, por lo que fueron eliminadas, reduciendo el número de características a 67 [12].
6. Manejo de valores infinitos: Las variables “Paquetes por segundo en el flujo” y “Bytes por segundo en el flujo” presentaron valores infinitos derivados de divisiones entre duraciones extremadamente pequeñas. Siguiendo prácticas estándar de preprocesamiento numérico [14], estos valores fueron reemplazados por nulos, permitiendo su tratamiento posterior mediante técnicas de imputación supervisada.
7. Estado final del conjunto de datos: El conjunto resultante contiene 2 604 791 muestras y 67 características numéricas. La clase benigna representa el 78.59 % del total, con un fuerte desbalance (ratio 186 104 respecto a la clase más minoritaria).

El resumen de las métricas estadísticas posterior a la limpieza de datos se puede visualizar en el Anexo E. De dicho resumen se puede observar que los únicos nulos que quedan son los que posteriormente se imputarían en el pipeline del entrenamiento de los modelos base, a su vez, se puede observar que no existen valores negativos en los mínimos ni valores infinitos en los máximos de cada muestra. A la par, con el objetivo de evaluar el impacto de limpieza sobre las variables del dataset, se realizó un análisis comparativo de estadísticas descriptivas antes y

después de la depuración. Para cada variable de las tablas presentadas en Anexos D y E se examinaron medidas de tendencia central, dispersión y rango intercuartílico. Los resultados como se puede verificar en dichas tablas muestran que las variaciones observadas fueron marginales, sin alteraciones sustanciales en la estructura estadística de las variables. De igual forma, se realizó un análisis comparativo de la distribución de clases antes y después del proceso de limpieza con el fin de verificar la preservación de la estructura original del dataset. La reducción de muestras se concentró en la clase mayoritaria, presentando una variación máxima de 2.128 puntos porcentuales. Las clases minoritarias no fueron modificadas en términos absolutos, observándose únicamente incrementos relativos derivados de la reducción del total de muestras. En consecuencia, se concluye que la distribución del dataset no fue alterada de manera significativa, manteniéndose el desbalance estructural original, en concordancia con las prácticas recomendadas para el tratamiento de datos desbalanceados [2].

| label                    | Antes       | Despues     | Diferencia Absoluta | Diferencia Absoluta % |
|--------------------------|-------------|-------------|---------------------|-----------------------|
| BENIGN                   | 0.803003664 | 0.785915262 | 0.017088402         | 2.1280603             |
| DoS Hulk                 | 0.081629805 | 0.088710764 | 0.007080959         | 8.674477146           |
| PortScan                 | 0.05614427  | 0.061014492 | 0.004870222         | 8.674477146           |
| DDoS                     | 0.045227348 | 0.049150584 | 0.003923236         | 8.674477146           |
| DoS GoldenEye            | 0.003636148 | 0.003951565 | 0.000315417         | 8.674477146           |
| FTP-Patator              | 0.002804211 | 0.003047461 | 0.000243251         | 8.674477146           |
| SSH-Patator              | 0.002083199 | 0.002263905 | 0.000180707         | 8.674477146           |
| DoS slowloris            | 0.002047519 | 0.002225131 | 0.000177612         | 8.674477146           |
| DoS Slowhttptest         | 0.0019426   | 0.00211111  | 0.00016851          | 8.674477146           |
| Bot                      | 0.000694517 | 0.000754763 | 6.02457E-05         | 8.674477146           |
| Web Attack Brute Force   | 0.000532369 | 0.000578549 | 4.61802E-05         | 8.674477146           |
| Web Attack XSS           | 0.000230328 | 0.000250308 | 1.99798E-05         | 8.674477146           |
| Infiltration             | 1.27175E-05 | 1.38207E-05 | 1.10318E-06         | 8.674477146           |
| Web Attack Sql Injection | 7.41855E-06 | 8.06207E-06 | 6.4352E-07          | 8.674477146           |
| Heartbleed               | 3.88591E-06 | 4.22299E-06 | 3.37082E-07         | 8.674477146           |

Tabla 1. Distribuciones antes y después de la limpieza de datos

Por último, el “pipeline” descrito para la limpieza de datos se resume en el siguiente diagrama:




Figura 3. Pipeline para Limpieza de Dataset de Intrusiones

### **Desarrollo: Segunda Parte: Modelos Base**

El objetivo de esta fase es establecer una línea base de rendimiento mediante la implementación de modelos de aprendizaje automático convencionales, categorizados como técnicas modernas para el manejo de datos tabulares de intrusiones acorde a la investigación previamente presentada de estado del arte. Estos modelos permitirán cuantificar la capacidad de discriminación inicial y servirán como punto de referencia a superar mediante la arquitectura de Mixture of Experts. Para este estudio, se seleccionaron tres algoritmos pilares: Random Forest, XGBoost y Redes Neuronales diseñadas para datos tabulares. La evaluación se centra en la métrica F1-Score Macro, seleccionada específicamente para mitigar el sesgo hacia las clases mayoritarias y garantizar que las clases minoritarias (intrusiones) posean el mismo peso en la evaluación del modelo. Adicionalmente, se analizarán el Recall por clase y las matrices de confusión para diagnosticar la correcta identificación de tráfico benigno y las intrusiones.

Para asegurar la reproducibilidad y la robustez de los modelos, se diseñó un flujo de trabajo (pipeline) estructurado de la siguiente manera:

1. **Partición de Datos:** División estratificada en conjuntos de entrenamiento, validación y prueba (70%, 15%, 15%) para preservar la distribución de clases en todos los subconjuntos/
2. **Codificación de Etiquetas:** Transformación de las etiquetas categóricas en valores numéricos, ajustando el codificador exclusivamente con los datos de entrenamiento.



3. **Normalización:** Aplicación de un escalado estándar para garantizar que las magnitudes de las características favorezcan la convergencia de los modelos basados en gradientes o distancias.
4. **Imputación por Clase:** Se implementó una estrategia de imputación por clase mediante regresores bayesianos y bosques aleatorios. Tras un análisis de preservación de la media y distribución, se seleccionó el regresor bayesiano por su estabilidad matemática. La comparativa de ambos imputadores se observa en el Anexo F.
5. **Sobremuestreo con Análisis de Artefactos (opcional):** Aplicación de técnicas de sobremuestreo sintético en set de entrenamiento. Se incluyó análisis de artefactos mediante vecinos cercanos para identificar generación de muestras sintéticas que puedan generar ruido.
6. **Selección de Características (opcional):** Uso de métodos supervisados basados en selección de características con base en los labels a nivel de cada clase para determinar la cantidad de características suficientes para maximizar la predictibilidad del modelo. Se decide no optar por extracción de características tipo PCA para evitar el riesgo de relacionar entre sí características que puedan aportar a distinción de clases minoritarias. También se incluyó en los experimentos la omisión de la selección de características.
7. **Optimización de parámetros de modelos:** Uso del framework Optuna para la búsqueda bayesiana de parámetros óptimos, maximizando el F1-Score Macro tras múltiples experimentos con hiperparámetros acordes a cada uno de los tres tipos de modelos (Random Forest, XGBoost y Redes Neuronales).

A continuación, se muestra gráficamente el pipeline previamente detallado para la generación de los modelos base:




Figura 4. Pipeline para Generación de Modelos Base de Clasificación de Intrusiones

Dentro del pipeline descrito se ha implementado una serie de técnicas en los experimentos para mejorar el aprendizaje de los modelos. A continuación, se da un detalle de las técnicas fijas a implementar en los pipelines para mejorar el entrenamientos de los modelos base:

- **Imputación por Clase:** En ciberseguridad, los datos faltantes no suelen ser aleatorios. Imputar de forma general puede alterar la información de un ataque. En el presente caso, al usar regresores bayesianos por clase, el modelo estima los valores faltantes basándose en el comportamiento específico de cada tipo de tráfico, manteniendo la integridad de los datos de cada ataque [15]
- **Optimización con Optuna:** A diferencia de un Grid Search tradicional, Optuna emplea el algoritmo Tree-structured Parzen Estimator. Este método de optimización bayesiana permite explorar el espacio de hiperparámetros de forma inteligente, priorizando regiones prometedoras y descartando configuraciones ineficientes mediante mecanismos de poda. Esta eficiencia es crítica ante la alta dimensionalidad del dataset de intrusiones donde la generación de experimentos puede llegar a ser costosa [18].

A su vez, se seleccionaron técnicas las cuales se fueron valorando de manera individual y finalmente de manera conjunta en los experimentos llevados a cabo para cada uno de los

algoritmos de clasificación seleccionados. El detalle de cada uno de los experimentos se describe posteriormente en el presente documento:

- **SMOTE, SMOTE-ENN y SMOTE-Tomek:** El uso de técnicas de sobremuestreo ha demostrado que aporta al aprendizaje de modelos con clases desbalanceadas. Para el presente caso se seleccionó el sobremuestreo simple de tipo SMOTE y se complementó el mismo con técnicas como SMOTE-ENN (Edited Nearest Neighbors) y Tomek Links las cuales tienen métodos de limpieza post-muestreo, eliminando ejemplos que generan ambigüedad en las fronteras de decisión [16].
- **Pesos de Clase Dinámicos:** Debido a que algunas clases son extremadamente escasas, incluso el sobremuestreo puede no ser suficiente. Ante aquello, se implementaron funciones de costo para penalizar con mayor severidad los errores en clases raras. Para la selección de las funciones de pesos se llevó a cabo un análisis de distribución y de pesos para evitar asignaciones extremadamente bajas o altas. Tras dicho análisis se optaron para los experimentos por las funciones de tipo: Effective Samples, Polinomial, Focal y Balanced [17]. No se implementó pesos manuales por clases para generar boosting como se ha verificado que se ha implementado en otras investigaciones debido a que se considera que el mismo incluye un riesgo de introducir sesgo manual.
- **Selección de características por F-Anova y Árboles Clasificadores:** La selección de F-ANOVA y Árboles Clasificadores para selección de características permite evaluar dos enfoques algorítmicos eficientes e interpretables. Se eligió F-ANOVA como técnica de filtrado para modelar dependencias lineales mediante análisis de varianza. Y en contraparte, los Árboles Clasificadores se incluyeron como técnica integrada para capturar interacciones multivariadas y relaciones no lineales mediante la reducción de impureza. Se busca valorar ambas técnicas sobre los datos de tráfico de red.

- **Función de pérdida de tipo Focal Loss:** En la clasificación de intrusiones, la abrumadora mayoría de tráfico normal genera ejemplos fáciles de predecir. La implementación de Focal Loss aborda este problema al reducir dinámicamente el peso asignado a estas instancias de alta confianza. Para el presente caso, el uso de esta función dirige el foco de atención del modelo hacia los ejemplos más difíciles de clasificar, como ataques sofisticados por lo que en los modelos que soportan funciones de pérdida como XGBoost o Redes Neuronales se buscó validar el aporte de la función Focal Loss [25].
- **Agrupación de Familias de Ataques Web:** Se observó a lo largo de los experimentos descritos que ataques como SQL Injection, XSS y Brute Force comparten características de red similares a nivel de transporte por lo que los modelos se confundían entre dichas clases a la hora de intentar hacer una clasificación exacta. De modo que dentro de los experimentos se valoró el aporte a las métricas de agrupar labels de un mismo tipo de ataques.

A continuación, como parte de la presente sección se detallan los pormenores y resultados de los experimentos para los modelos base por cada uno de los tres tipos de algoritmos seleccionados para la clasificación. Cabe destacar que por cada experimento se generaron logs incluyendo los datos a nivel de modelo y de igual forma se indica para cada experimento los mejores resultados obtenidos por cada una de las métricas de interés en lo relacionado a la clasificación de intrusiones:

- **Random Forests**

Se seleccionó el algoritmo de Random Forest para la clasificación de intrusiones debido a su alta capacidad para identificar características relevantes y modelar relaciones complejas en los datos. Al ser un método de ensemble learning, reduce el sobreajuste y mejora la generalización, además de ser robusto frente a un dataset desbalanceado, favoreciendo la detección de clases minoritarias. Asimismo, permite estimar la importancia de las variables y mantiene un buen equilibrio entre rendimiento y eficiencia computacional, lo que lo hace adecuado para sistemas de detección en tiempo real. Como referencia, el estudio de Chavan y Alone [19], utilizando el dataset CIC-IDS2017, reporta un desempeño destacado del modelo, alcanzando un F1-score macro de 96.7%, junto con altos valores de precisión y recall. Este resultado evidencia la efectividad de Random Forest para detectar múltiples tipos de ataques en escenarios reales.

Para todas las iteraciones, se utilizó Optuna como motor de optimización bayesiana bajo las siguientes condiciones constantes:

- Métrica Objetivo: Maximización del F1-Score Macro en el set de validación.
- Validación: División estratificada (Benignos vs. Ataques) para asegurar representatividad.

Espacio de Búsqueda de Hiperparámetros:

- `n_estimators`: [50, 400]
- `max_depth`: [10, 60]
- `min_samples_split`: [2, 15]
- `max_features`: ['sqrt', 'log2', None]

- **XGBoost:**

Se seleccionó el algoritmo XGBoost para la clasificación de intrusiones debido a su alta eficiencia y capacidad para modelar relaciones complejas no lineales mediante la construcción

secuencial de árboles de decisión. Al ser un algoritmo basado en gradient boosting, penaliza los errores de los árboles anteriores, mejorando continuamente la clasificación de las instancias más difíciles respecto al uso de Random Forests. Además, incluye técnicas de regularización integradas que previenen el sobreajuste y aprovecha la aceleración por hardware, lo que permite procesar grandes volúmenes de datos con una alta eficiencia computacional [20].

Como referencia, el estudio de Sow y Ada [21], utilizando de igual forma el dataset CIDS 2017, reporta un desempeño destacado del modelo XGBoost, alcanzando una precisión macro de 99%. Este resultado evidencia la efectividad del modelo para minimizar falsos negativos en escenarios de detección de intrusiones.

Para todas las iteraciones, se utilizó Optuna como motor de optimización bayesiana bajo las siguientes condiciones constantes:

- Métrica Objetivo: Maximización del F1-Score Macro en el set de validación.
- Validación: División estratificada (Benignos vs. Ataques) para asegurar representatividad.

Espacio de Búsqueda de Hiperparámetros:

- `n_estimators`: [150, 450]
- `max_depth`: [6, 15]
- `learning_rate`: [0.01, 0.2] (escala logarítmica)
- `subsample`: [0.6, 1.0]
- `colsample_bytree`: [0.6, 1.0]

- **Redes Neuronales**

Se seleccionó el uso de Redes Neuronales Profundas, transitando desde un Perceptrón Multicapa (MLP) hacia arquitecturas de Redes Residuales (ResNet) adaptadas para datos tabulares debido a su capacidad superior para extraer representaciones jerárquicas y patrones altamente complejos en el tráfico de red. A diferencia de los modelos basados en árboles, las redes neuronales pueden escalar masivamente con los datos y beneficiarse de la aceleración por hardware. Además, la integración de conexiones residuales previene el problema del desvanecimiento del gradiente, permitiendo entrenar redes más profundas que modelen interacciones sutiles entre las variables de red [5].

Como referencia, investigaciones recientes en el dominio de detección de intrusiones [5] destacan que las arquitecturas profundas optimizadas logran reducir significativamente las tasas de falsos positivos en conjuntos de datos complejos como CIC-IDS2017, justificando su implementación para capturar intrusiones que métodos tradicionales podrían omitir.

Se continuó utilizando Optuna como motor de optimización bajo las siguientes condiciones constantes:

- Métrica Objetivo: Maximización del F1-Score Macro en el set de validación.
- Validación: División estratificada para asegurar representatividad de las clases.

Espacio de Búsqueda de Hiperparámetros:

- Tamaño de lote: [4096, 8192, 16384]
- Número de capas: [2, 10]
- Neuronas por capa: [512, 1024]
- Tasa de aprendizaje: [1e-4, 1e-3] (escala logarítmica)
- Número de épocas: [50,100]

- **Descripción de Experimentos para los algoritmos**

Atendiendo a las mejores prácticas de experimentación en aprendizaje automático, se estructuró una metodología basada en bloques controlados. Esta aproximación como se ha evidenciado en la investigación de mejoras metodológicas de Saini et. al. [22] permite aislar el impacto de cada técnica garantizando una interpretación correcta de los resultados y evitando el enmascaramiento de las métricas:

- **Experimento 1 - Definición de Línea Base Comparativa:** Se estableció un punto de base evaluando únicamente el modelo sobre el dataset original. En esta fase no se aplicó ninguna técnica de sobremuestreo, asignación de pesos dinámicos, reducción de dimensionalidad, ni agrupación de clases. Este modelo servirá como control absoluto para medir la ganancia o pérdida real de rendimiento introducida por las técnicas posteriores y a su vez funcionará como punto de comparación respecto a los modelos Mixture of Experts para comparar modelos puros entre sí [23].
- **Experimento 2 - Evaluación Aislada de Técnicas de Sobremuestreo:** Partiendo del modelo base, se evaluó de manera individual el impacto de la generación de datos sintéticos. Se ejecutaron pruebas separadas para SMOTE simple, SMOTE-ENN y SMOTE-Tomek [6]. El objetivo de este bloque fue identificar exclusivamente cómo reacciona el modelo al balanceo de clases orientado a aumentar las muestras de clases minoritarias para mejorar el aprendizaje.
- **Experimento 3 - Evaluación Aislada de Pesos de Clase Dinámicos:** Volviendo al dataset original, se integraron de forma independiente las funciones de penalización de costos: Effective Samples, Polinomial, Focal y Balanced. Este bloque controló cómo el modelo maneja el desbalanceo severo únicamente a través del peso de los errores en el proceso de aprendizaje [16].



- **Experimento 4 - Evaluación Aislada de Selección de Características:** De manera independiente al balanceo y a los pesos, se aplicaron técnicas de selección de variables sobre el modelo base. Se contrastó el rendimiento utilizando un enfoque de filtrado (F-ANOVA) frente a un enfoque integrado (Árboles Clasificadores). Esto permitió aislar y valorar el aporte específico de la selección de características siguiendo la recomendación de una investigación citada del Instituto de Tecnología de Indonesia respecto a CIDS [24]
- **Experimento 5 - Evaluación Aislada de Funciones de Pérdida:** En los modelos basados en optimización de gradiente como XGBoost o Redes Neuronales, se evaluó de forma aislada el impacto de la función Focal Loss. Se partió de un modelo base configurado con la función estándar de Entropía Cruzada como punto de control [25]. El objetivo de esta comparación directa fue medir exclusivamente si penalizar los ejemplos fáciles de la clase mayoritaria logra enfocar el aprendizaje hacia los ataques minoritarios difíciles de clasificar.
- **Experimento 6 - Integración Conjunta de Mejores Técnicas:** Una vez identificados los enfoques individuales con mejor rendimiento en los experimentos 2, 3, 4 y 5, se procedió a combinarlos. Este experimento integró la mejor técnica de sobremuestreo, la mejor función de peso dinámico, el mejor selector de características y la mejor función de pérdida.
- **Experimento 7 - Análisis de Impacto por Agrupación de Clases:** Como estudio adicional, se evaluó el impacto directo de agrupar las clases minoritarias de ataque Web (SQL Injection, XSS y Brute Force) bajo un único label. Se comparó el rendimiento de este enfoque frente a la línea base comparativa del problema multiclase original de forma completamente aislada. El objetivo de este experimento fue justificar empíricamente si esta agrupación aporta a las métricas objetivo de la clasificación

considerando que los ataques web tienen misma firma de características de tráfico independientemente del tipo de técnica de intrusión aplicada a nivel de capa de aplicación [26]

- **Mejores Resultados de Modelos Base en Set de Pruebas**
- **Random Forest**

| Experimento   | Técnica                | F1 Macro | Recall Macro | Precisión Macro | Observación Principal                                                                  |
|---------------|------------------------|----------|--------------|-----------------|----------------------------------------------------------------------------------------|
| 1 (base)      | Ninguna                | 0.85     | 0.85         | 0.86            | Alta profundidad y número de estimadores, junto con el uso completo de características |
| 2             | SMOTE_ENN              | 0.84     | 0.87         | 0.84            | SMOTE-ENN, alta profundidad y división de hojas más restrictivo                        |
| 3             | Balanced               | 0.87     | 0.88         | 0.87            | Pesos balanced mejora F1-macro, con profundidad moderada                               |
| 4             | Tree                   | 0.85     | 0.85         | 0.87            | La selección de características mantiene rendimiento, apoyada por alta profundidad     |
| 5 (no aplica) |                        |          |              |                 |                                                                                        |
| 6             | Solo Pesos<br>Balanced | 0.86     | 0.89         | 0.84            | Al igual que en experimento 3 los mejores resultados se obtuvieron con pesos balanced  |
| 7             | Agrupar clases<br>Web  | 0.93     | 0.91         | 0.98            | Agrupar clases web más modelo de alta complejidad y uso total de características       |

Tabla 2. Métricas de Mejores Modelos Random Forest por experimento

- **XGBoost**

| Experimento | Técnica                | F1 Macro | Recall Macro | Precisión Macro | Observación Principal                                                                   |
|-------------|------------------------|----------|--------------|-----------------|-----------------------------------------------------------------------------------------|
| 1 (base)    | Ninguna                | 0.83     | 0.82         | 0.86            | Profundidad y número de estimadores altos junto con tasa de muestreo parcial            |
| 2           | SMOTE<br>TOMEK         | 0.83     | 0.85         | 0.83            | Con SMOTE-Tomek más el uso de muestreo parcial y una tasa de aprendizaje baja           |
| 3           | Balanced               | 0.86     | 0.87         | 0.85            | Pesos balanced apoyados por un alto número de estimadores y muestreo parcial            |
| 4           | F-<br>classification   | 0.83     | 0.81         | 0.85            | Selección de características reduce rendimiento, aunque es estable con muestreo parcial |
| 5           | Focal Loss             | 0.83     | 0.82         | 0.86            | Se observa ligera degradación con Focal Loss en XGBoost, pese a muestreo casi completo  |
| 6           | Solo Pesos<br>Balanced | 0.87     | 0.89         | 0.85            | Pesos balanced impulsa el rendimiento, con profundidad moderada y muestreo parcial      |
| 7           | Agrupar clases<br>Web  | 0.90     | 0.87         | 0.98            | Agrupación de clases logra un F1-macro casi perfecto incluso con baja profundidad.      |

Tabla 3. Métricas de Mejores Modelos XGBoost por experimento

- **Redes Neuronales tipo Perceptrón Multicapa**

| Experimento | Técnica                        | F1<br>Macro | Recall<br>Macro | Precisión<br>Macro | Observación Principal                                                              |
|-------------|--------------------------------|-------------|-----------------|--------------------|------------------------------------------------------------------------------------|
| 1           | Ninguna                        | 0.77        | 0.75            | 0.92               | Arquitectura poco profunda tipo bottleneck con alto tamaño de lote                 |
| 2           | SMOTE<br>TOMEK                 | 0.75        | 0.82            | 0.79               | Con SMOTE-Tomek se mantiene un rendimiento limitado                                |
| 3           | Polinomial                     | 0.73        | 0.72            | 0.85               | La ponderación polinómica aporta una mejora apoyada por mayor profundidad          |
| 4           | Tree                           | 0.73        | 0.71            | 0.92               | La selección no aporta mejoras, manteniendo un rendimiento similar al base         |
| 5           | Focal Loss                     | 0.75        | 0.73            | 0.91               | Focal Loss ofrece una mejora apoyada por mayor regularización                      |
| 6           | Focal Loss +<br>SMOTE<br>TOMEK | 0.76        | 0.83            | 0.80               | Combinación de técnicas aporta una mejora con una arquitectura simple              |
| 7           | Agrupar clases<br>Web          | 0.79        | 0.89            | 0.75               | Agrupación de clases impulsa el rendimiento acompañado de una mayor regularización |

Tabla 4. Métricas de Mejores Modelos Red Neuronal de tipo Perceptrón Multicapa por experimento

Como complemento a los resultados mostrados en las tablas superiores a nivel de cada uno de los modelos base, se puede observar del lado del Anexo G las respectivas matrices de confusión para obtener un detalle más exacto de la identificación cuantitativa a nivel de la distinción de intrusiones respecto a tráfico benigno.

- **Discusión de Resultados**

### **Discusión de Resultados de los Modelos Base**

- Los experimentos evidencian que los modelos basados en árboles de decisión (Random Forest y XGBoost) superan consistentemente a las Redes Neuronales estándar para este conjunto de datos. Random Forest se posiciona como el modelo base más sólido, logrando un F1 Macro de 0.85 sin ninguna técnica adicional, mientras que la Red Neuronal base se estanca en un 0.77. Esto confirma la dificultad inherente de los perceptrones multicapa (MLP) tradicionales para modelar este tipo de datos tabulares sin arquitecturas especializadas [27].
- En las tres arquitecturas evaluadas, el ajuste de penalizaciones (Balanced / Solo Pesos Balanced) resultó ser una estrategia considerablemente más efectiva y estable que el sobremuestreo con técnicas como SMOTE\_ENN o SMOTE TOMEK. En Random Forest y XGBoost, el uso de pesos incrementó el F1 Macro a 0.87 y el Recall Macro a niveles de 0.89. Por el contrario, SMOTE tendió a degradar ligeramente el F1 Macro o mantenerlo estático, sugiriendo que la introducción de ruido sintético no favorece las fronteras de decisión complejas de estos ataques [16].
- El experimento 7 ("Agrupar clases Web") generó el incremento de rendimiento más drástico en todos los modelos. En Random Forest, esta técnica disparó el F1 Macro a 0.93 y la precisión a 0.98. En XGBoost el F1 subió a 0.90, y en la Red Neuronal a 0.79. Esto indica que existe un alto grado de solapamiento en las características de las subclases de ataques Web; al unificarlas, se reduce el ruido de clasificación y los algoritmos logran mejores métricas.

- La implementación de Focal Loss y Solo Focal Loss en la Red Neuronal logró su objetivo principal de incrementar el Recall Macro (pasando de 0.75 en el base a 0.83 con Solo Focal Loss), mejorando la detección de ataques minoritarios. Sin embargo, esto tuvo un costo directo en la Precisión Macro, limitando el F1 a 0.76.
- Las técnicas de selección y transformación de características (Tree, F-classification, Polinomial) no aportaron mejoras. En el caso de las Redes Neuronales, redujeron el F1 Macro a 0.73, y en XGBoost lo mantuvieron en 0.83 con caídas en el Recall. Esto sugiere que prescindir de características originales penaliza la detección de ataques con firmas sutiles.
- La brecha de rendimiento entre el Random Forest optimizado (F1 de 0.93) y la mejor Red Neuronal (F1 de 0.79) fundamenta técnicamente los desarrollos posteriores del proyecto. Demuestra que para que el aprendizaje profundo sea competitivo en este dominio, no basta con ajustes de hiperparámetros o funciones de pérdida en un MLP simple, sino que es estrictamente necesario implementar arquitecturas que capturen relaciones más complejas, como el ensamble dinámico propuesto en el Mixture of Experts (MoE) o los mecanismos de un modelo de red neuronal más orientado a datos tabulares [8].

### **Desarrollo: Tercera Parte: Mixture of Experts**

Un modelo Mixture of Experts (MoE) consiste en una arquitectura compuesta por submodelos especializados, denominados expertos, y un modelo integrador de tipo compuerta (gating network). Los expertos se especializan en clasificar subconjuntos específicos de datos, mientras que la compuerta aprende a ponderar y seleccionar las mejores subredes para cada

instancia. La clasificación final se genera mediante la combinación de las probabilidades de salida de cada experto y los pesos asignados por la compuerta [28].

En contextos como el del presente proyecto con conjuntos de datos severamente desbalanceados, ciertas categorías presentan una mayor complejidad de clasificación. Esto se debe a la escasez de muestras para definir fronteras de decisión adecuadas o a la dificultad inherente de identificar ataques sofisticados.

Para abordar estas limitaciones, que suelen afectar a los modelos de entrenamiento general, se justifica la implementación de una arquitectura MoE que fomente la especialización en vectores de ataque específicos con el fin de incrementar el rendimiento predictivo para lo cual en la presente sección se busca emplear este tipo de modelo para lograr una métrica F1-score macro superior al modelo base definido en la sección previa [8].

Por recordar, dicho modelo base consiste en el algoritmo tipo Random Forest sin aplicación de técnicas adicionales de mejora de modelos (ej. sobremuestreo, selección de características, ponderación de pesos) a manera de realizar una comparación directa de modelos. A continuación, se describen los detalles del modelo base Random Forest tomado para la comparativa base:

- **Modelo Base:**
  - Tipo de Modelo: Random Forest
  - Número de estimadores: 314
  - Profundidad máxima: 83
  - Muestras mínimas para división: 5
  - Muestras mínimas por hoja: 2

- Características máximas: Ninguno
- Criterio de división: Entropía

- **Métricas Modelo Base:**

- F1-macro: 0.85
- Precisión macro: 0.85
- Recall macro: 0.86

Con base en dicho modelo el objetivo será mejorar la métrica de F1-score macro y para aquello, se implementaron arquitecturas MoE incrementales las cuales se detallan a continuación:

### **1. Arquitectura de tipo “Hard Gating” Top-K con expertos tipo Perceptrón Multicapa**

A continuación, se detalla la configuración de la primera arquitectura implementada:

- Estrategia de Partición y Balanceo Específico: El conjunto de entrenamiento se segmentó en seis subconjuntos especializados, mapeando las clases originales hacia grupos lógicos de ataques. Para contrarrestar el desbalanceo severo, se integró una tubería de sobremuestreo dinámico, evaluando el impacto de técnicas como SMOTE, SMOTE-Tomek y SMOTE-ENN sobre el espacio de características previo a la inyección de muestras sintéticas.

Esto se debe a que, en arquitecturas Mixture of Experts con desbalance de clases, es recomendable aplicar técnicas de sobremuestreo a nivel de los subconjuntos de entrenamiento de cada experto, con el fin de garantizar una cantidad suficiente de



muestras para el adecuado entrenamiento de los modelos especializados. La conformación de los expertos se definió siguiendo lineamientos de investigaciones previas, organizándolos según el volumen de ataques (de mayor a menor) y considerando familias de ataques de difícil clasificación, a partir de las cuales se generaron subconjuntos de datos específicos para cada experto [29].

- Experto 1: Tráfico Benigno.
  - Experto 2: Ataques Mayoritarios (DDoS, DoS Hulk, PortScan).
  - Experto 3: Ataques de Frecuencia Media (DoS GoldenEye, DoS Slowhttptest, DoS slowloris, FTP-Patator, SSH-Patator).
  - Experto 4: Ataques Botnet.
  - Experto 5: Ataques Web (Brute Force, SQL Injection, XSS).
  - Experto 6: Ataques Minoritarios (Heartbleed, Infiltration).
- Diseño y Pre-entrenamiento Individual de Expertos: Cada experto se modeló como un Perceptrón Multicapa adaptado a datos tabulares, incorporando capas de Batch Normalization, Dropout y funciones de activación LeakyReLU/GELU. La topología de la red (profundidad y unidades por capa) y la tasa de aprendizaje se optimizaron de forma independiente para cada experto mediante Optuna y se empleó Focal Loss como función de costo para penalizar los errores en las muestras de mayor dificultad dentro de cada subconjunto [25].
  - Mecanismo de Enrutamiento: El orquestador del ensamble se construyó mediante una red neuronal paralela con una capa de salida Softmax, encargada de emitir los pesos de contribución [28]. Este mecanismo se encarga de evaluar el vector de características de

entrada y calcula la probabilidad condicional de competencia de cada experto para la clasificación del flujo de red correspondiente.

- **Enrutamiento Estricto (Top-K):** Posterior a la validación del enrutamiento probabilístico continuo, se integró una variante de decisión estricta de tipo Top-K. Este esquema restringe la salida final del MoE a las predicciones de los K expertos con mayor probabilidad por muestra, aislando el resto mediante una máscara de ceros con el objetivo de mitigar el ruido predictivo. Dicho valor K se optimizó de igual forma con el uso de Optuna [30].
- **Pipeline de Entrenamiento por Fases:** La consolidación de la arquitectura se estructuró en una secuencia de acoplamiento de tres etapas de entrenamiento para garantizar la convergencia. Esta estructura de aprendizaje se considera state-of-the-art ya que permite tener un mejor control sobre el proceso progresivo de mejora del modelo en el entendimiento de patrones para clasificaciones [28]. A continuación, se detalla la estructura del mismo empleada en la primera arquitectura:
  - **Pre-entrenamiento:** Entrenamiento y almacenamiento independiente de los seis expertos.
  - **Entrenamiento de Compuerta:** Instanciación del MoE congelando los gradientes de los expertos para entrenar exclusivamente la red de enrutamiento.
  - **Refinamiento Conjunto:** Descongelamiento de todos los parámetros globales y ejecución de una fase de ajuste fino con una tasa de aprendizaje reducida, preservando la especialización previa de los expertos.

**Diagrama:**




Figura 5. Arquitectura MoE “Hard Gating” Top-K con expertos Perceptrón Multicapa

## 2. Arquitectura de tipo “Soft Gating” con expertos tipo Perceptrón Multicapa

A continuación, se detalla la configuración de la segunda arquitectura implementada:

- Estrategia de Partición y Balanceo Específico: En esta segunda iteración, se reestructuró la taxonomía del ensamble, reduciendo la partición a cinco subconjuntos

especializados. Esta agrupación se fundamentó en el análisis de las matrices de confusión previas, con el objetivo de consolidar clases de ataques que exhiben patrones similares y resultan difíciles de distinguir por un modelo general, aprovechando así la especialización de los expertos. Esta técnica se implementó como aporte propio considerando que se requería mejorar la clasificación focalizando el entrenamiento entre expertos que tienen fronteras de decisión compartidas.

Se optimizó la detección agrupando el tráfico benigno con aquellos ataques que tienden a camuflarse en el flujo normal, y se dividieron las familias de denegación de servicio en categorías más granulares. Se conservó el pipeline de sobremuestreo dinámico, evaluando las técnicas SMOTE, SMOTE-Tomek y SMOTE-ENN. La nueva distribución de expertos se definió de la siguiente manera:

- Experto 1: Tráfico Benigno y Ataques Camuflados (tráfico con patrones similares al no malicioso: Benigno, Bot, Brute Force, SQL Injection, XSS).
  - Experto 2: Ataques Mayoritarios (DDoS, DoS Hulk, PortScan).
  - Experto 3: Ataques DoS (DoS GoldenEye, DoS slowloris, DoS Slowhttptest).
  - Experto 4: Ataques Patator (FTP-Patator, SSH-Patator).
  - Experto 5: Ataques Minoritarios (Heartbleed, Infiltration).
- 
- Diseño y Pre-entrenamiento Individual de Expertos (TabularMLP): Se mantuvo el diseño base, modelando cada experto como un Perceptrón Multicapa (MLP) adaptado a datos tabulares, integrando capas de Batch Normalization, Dropout y funciones de activación LeakyReLU/GELU. La arquitectura topológica y los hiperparámetros fueron optimizados dinámicamente de forma individual mediante Optuna, empleando Focal

Loss como función de costo debido a sus reconocidos beneficios en investigaciones de clasificación de intrusiones al apoyar el aprendizaje de clases minoritarias [25].

- **Mecanismo de Enrutamiento (Soft Gating):** En esta arquitectura, el enrutador opera como un coordinador que analiza los vectores de características de entrada y determina la idoneidad de cada experto, asignándoles una probabilidad mediante una capa Softmax. Esta estrategia de enrutamiento suave permite que todos los expertos contribuyan simultáneamente a la predicción final; sin embargo, el nivel de influencia de cada uno está estrictamente ponderado por el coeficiente de confianza emitido por la red de enrutamiento [31].
- **Pipeline de Entrenamiento y Refinamiento Diferencial:** Para favorecer la convergencia del ensamble bajo el esquema de Soft Gating, se optimizó el proceso de entrenamiento implementando una actualización simultánea con tasas de aprendizaje diferenciales. Se permitió el ajuste concurrente de toda la arquitectura (enrutador y expertos) sin congelar gradientes. Para lograrlo, se asignó una tasa de aprendizaje superior a la red de enrutamiento para acelerar su capacidad de delegación, mientras que a los expertos se les aplicó una tasa reducida para evitar la alteración abrupta de los pesos adquiridos durante el pre-entrenamiento. Este acoplamiento dinámico permitió la sinergia del sistema sin comprometer la especialización previa de las subredes [28].

Como se evidenciará en la sección de resultados, esta iteración arquitectónica logró superar el rendimiento del modelo base, consolidándose como el punto de partida óptimo para refinamientos posteriores en la aplicación de Mixture of Experts para la clasificación de intrusiones. A continuación, se presenta el diagrama esquemático de la arquitectura descrita.

#### **Diagrama:**




Figura 6.Arquitectura MoE “Soft Gating” con expertos Perceptrón Multicapa

### 3. Arquitectura de tipo “Soft Gating” con expertos tipo TabTransformer

- Diseño y Pre-entrenamiento Individual de Expertos (TabTransformer): La modificación estructural principal en esta tercera iteración radicó en la actualización de la arquitectura base de los expertos. Se reemplazó el Perceptrón Multicapa tradicional por la arquitectura TabTransformer. Este modelo integra mecanismos de autoatención

(Self-Attention) que permiten capturar de manera más efectiva las relaciones complejas y las interacciones latentes dentro de las características tabulares del tráfico de red [32].

De manera análoga a las fases precedentes, los cinco expertos fueron pre-entrenados de forma independiente para especializarse en sus respectivos subconjuntos. Se conservó intacta la taxonomía de agrupación de ataques y los conjuntos de datos de cada experto.

- **Mecanismo de Enrutamiento:** Con base en la estabilidad y los resultados empíricos previos, se mantuvo el esquema de enrutamiento continuo (Soft Gating). La red de enrutamiento actúa como el coordinador central: procesa el vector de características entrante y asigna un coeficiente de confianza (peso probabilístico) a cada experto TabTransformer. La predicción final se calcula mediante la combinación de las salidas de todos los expertos, donde la influencia de cada subred está estrictamente ponderada por el nivel de confianza otorgado por el enrutador [31].
- **Pipeline de Entrenamiento y Refinamiento Diferencial:** Para el acoplamiento óptimo de este ensamble, se preservó la estrategia de ajuste concurrente utilizando tasas de aprendizaje diferenciales. Se habilitó la actualización simultánea de los gradientes tanto en la red de enrutamiento como en los expertos TabTransformer. Se asignó una tasa de aprendizaje superior al enrutador para acelerar la convergencia de su lógica de delegación, mientras que a los expertos se les aplicó una tasa significativamente reducida [28]. Esta configuración permitió la adaptación sistémica del modelo en conjunto, evitando la degradación catastrófica y preservando las representaciones complejas de los ciberataques que los expertos adquirieron durante su fase de pre-entrenamiento.

### **Diagrama:**




Figura 7. Arquitectura MoE “Soft Gating” con expertos TabTransformer

- **Tabla comparativa de Resultados de Arquitectura Mixture of Experts contra Resultados de Modelos Base**



En la tabla siguiente se presentan los resultados del modelo de referencia (sin técnicas de mejora) basado en Random Forest, junto con los resultados de los modelos base de XGBoost y de la red neuronal MLP, así como los obtenidos mediante el enfoque de Mixture of Experts, con el fin de establecer una comparativa directa entre los distintos enfoques evaluados:

| Arquitectura                                               | Sobremuestreo<br>en sets de<br>entrenamiento | F1 Macro | Recall Macro | Precisión<br>Macro | Observación Principal                                              |
|------------------------------------------------------------|----------------------------------------------|----------|--------------|--------------------|--------------------------------------------------------------------|
| Random Forest                                              | N/A                                          | 0.84     | 0.85         | 0.86               | Mejor Arquitectura Base para<br>Modelo tipo Random Forest          |
| XGBoost                                                    | N/A                                          | 0.83     | 0.82         | 0.86               | Mejor Arquitectura Base para<br>Modelo tipo XGBoost                |
| Red Neuronal<br>MLP                                        | N/A                                          | 0.77     | 0.75         | 0.92               | Mejor Arquitectura Base para<br>Modelo tipo Red Neuronal<br>MLP    |
| Mixture of<br>Experts con<br>Expertos MLP y<br>Hard Gating | SMOTE                                        | 0.75     | 0.72         | 0.92               | Alta Precisión, pero baja<br>clasificación de ataques Web<br>y Bot |
|                                                            | SMOTE-ENN                                    | 0.76     | 0.75         | 0.87               | Alta Precisión, pero baja<br>clasificación de ataques Web          |
|                                                            | SMOTE Tomek                                  | 0.76     | 0.73         | 0.92               | Performance similar al<br>modelo con sets de tipo<br>SMOTE         |
| Mixture of<br>Experts con                                  | SMOTE                                        | 0.85     | 0.83         | 0.93               | Modelo iguala rendimiento<br>base, pero tiene dificultad en<br>Web |

|                                                                          |             |      |      |      |                                                              |
|--------------------------------------------------------------------------|-------------|------|------|------|--------------------------------------------------------------|
| Expertos MLP y<br>Soft Gating                                            | SMOTE-ENN   | 0.86 | 0.83 | 0.97 | Primer modelo MoE que logra superar a baseline en F1 Macro   |
|                                                                          | SMOTE Tomek | 0.85 | 0.82 | 0.96 | Modelo reduce mínimamente las métricas del MoE               |
| Mixture of<br>Experts con<br>Expertos<br>TabTransformer<br>y Soft Gating | SMOTE       | 0.88 | 0.87 | 0.93 | TabTransformer potencia la clasificación de clases difíciles |
|                                                                          | SMOTE-ENN   | 0.89 | 0.87 | 0.96 | El presente modelo logra las mejores métricas base para CIDS |
|                                                                          | SMOTE Tomek | 0.89 | 0.87 | 0.94 | Modelo de rendimiento similar y superior al baseline         |

Tabla 5. Métricas de Mejores Modelos MoE por arquitectura y sobremuestreo en subconjuntos de entrenamiento de expertos

De igual forma, complementado los resultados indicados en la tabla anterior, se procede a indicar del lado de Anexos las matrices de confusión (Ver Anexo H) para cada uno de los mejores resultados obtenidos en validaciones de set de pruebas a nivel de cada una de las tres arquitecturas MoE.

### Desarrollo: Cuarta Parte: Análisis de Resultados

El análisis comparativo del rendimiento entre el mejor modelo de línea base y las arquitecturas Mixture of Experts (MoE) revela hallazgos importantes sobre el comportamiento de los clasificadores frente a un conjunto de datos con desbalance extremo, el cual en el presente caso para clasificación de intrusiones presenta un ratio de desbalance de 206645.18 y una entropía

de 0.2837 [1], [2]. Cabe destacar que el presente escenario comparativo contempla estrictamente la comparación de modelos puros sin técnicas de mejora como pueden ser selección de características, ponderación de clases por pesos, entre otras. Bajo dicho contexto de comparación estricta de modelos puros la evaluación se centró primordialmente en la métrica F1-Score Macro para garantizar una medición equitativa que penalice los sesgos hacia el tráfico benigno [3].

### **Rendimiento de Modelos Base**

La fase de experimentación inicial evidenció que los algoritmos fundamentados en ensambles de árboles poseen una robustez inherente frente al desbalance estructural de los datos [21]. El clasificador Random Forest se consolidó como la línea base más sólida, logrando un F1-Score Macro de 0.85 sin la aplicación de técnicas de preprocesamiento adicionales [19]. De manera similar, XGBoost, al basarse en estimadores de tipo árbol de decisión, alcanzó un rendimiento destacado con un F1-Score Macro de 0.83 en su configuración estándar [20].

En contraste, la Red Neuronal profunda (Perceptrón Multicapa) mostró una severa limitación de convergencia bajo las mismas condiciones, estancándose en un F1-Score Macro de 0.77. Esta diferencia de 0.07 en la métrica confirma la dificultad técnica que presentan los modelos tradicionales de aprendizaje profundo para procesar características tabulares heterogéneas prescindiendo de arquitecturas especializadas [27].

Posteriormente, se implementaron diversas técnicas de aprendizaje automático con el objetivo de optimizar el rendimiento predictivo de los modelos base. Los resultados empíricos revelaron los siguientes comportamientos:

- La inyección de muestras para las clases minoritarias no generó un impacto positivo significativo y, en ciertos escenarios, provocó una degradación en las métricas [2], [17]. Este fenómeno se atribuye a que la introducción de ruido sintético altera negativamente las fronteras de decisión de los vectores de ataque [6].
- Se incorporaron funciones de penalización para incrementar el peso de los errores en las clases minoritarias. La función de tipo Balanced produjo un incremento de 0.03 en el F1-Score Macro de los modelos basados en árboles, impactando positivamente en la capacidad de generalización [2]. La ineficacia de funciones de menor severidad sugiere que los escenarios de desbalance extremo exigen esquemas de penalización rigurosos [25].
- La aplicación de técnicas como F-ANOVA (filtrado) y árboles clasificadores (métodos integrados) no produjo mejoras significativas sobre las métricas establecidas [24], indicando que la dimensionalidad original preserva firmas de red necesarias para la detección [4].
- Ante la alta tasa de confusión en la clasificación de ataques Web, se procedió a unificar estas categorías en una sola etiqueta. Esta reestructuración taxonómica elevó sustancialmente el rendimiento, alcanzando un F1-Score Macro de hasta 0.93. Dicho incremento se justifica técnicamente debido a que estas intrusiones comparten arquitecturas y firmas de tráfico a nivel de red análogas, lo que dificulta la distinción granular exacta por parte de un modelo general [26].

## **Rendimiento de Mixture of Experts:**

El desarrollo de una arquitectura de inteligencia artificial basada en el paradigma de Mixture of Experts respondió a la necesidad de mitigar las deficiencias de convergencia de los modelos de aprendizaje profundo convencionales frente a datos tabulares con desbalance extremo [17], [28]. Mientras que una red neuronal estándar se estancó en un F1-Score Macro de 0.77, el enfoque delegativo de MoE permitió escalar la capacidad predictiva mediante la especialización de subredes [7].

La progresión del diseño arquitectónico, dividida en tres fases fundamentales, ilustra el proceso de optimización técnica necesario para superar la robustez de los ensambles de árboles de decisión.

- En la primera fase de experimentación, se implementó una arquitectura de enrutamiento estricto o Hard Gating Top-K, empleando seis expertos configurados como Perceptrones Multicapa (MLP) [30]. Bajo este esquema, la red de enrutamiento emitía una máscara para seleccionar exclusivamente a los expertos con mayor probabilidad condicional, aislando al resto del ensamble. Los resultados de esta iteración arrojaron un F1-Score Macro máximo de 0.76, utilizando técnicas de sobremuestreo híbrido como SMOTE-Tomek y SMOTE-ENN [16]. Desde una perspectiva analítica, este modelo no logró alcanzar la línea base del Random Forest debido a las limitaciones intrínsecas del gating rígido. Al forzar una decisión excluyente en la compuerta, se descarta información probabilística crítica sobre ataques que comparten firmas de red

solapadas, lo que introduce ruido predictivo y dificulta la resolución de ambigüedades en muestras de ataque complejos.

- La segunda iteración marcó un punto de inflexión técnica al transicionar hacia un mecanismo de Soft Gating con expertos MLP y un refinamiento basado en tasas de aprendizaje diferenciales [31]. En esta configuración, la compuerta operó mediante una capa Softmax continua, permitiendo que la predicción final fuera el resultado de una colaboración ponderada entre todos los expertos. Además, se optimizó la taxonomía del ensamble reduciendo la partición a cinco subconjuntos especializados, agrupando clases de ataques con patrones similares para potenciar la capacidad de especialización [1]. Esta arquitectura alcanzó un F1-Score Macro de 0.86, logrando por primera vez superar el objetivo de sobrepasar la línea base del modelo Random Forest. La mejora se justifica técnicamente por el enrutamiento probabilístico, que permite mitigar errores individuales mediante el consenso del ensamble, y por el ajuste fino diferencial que aceleró la capacidad de delegación de la compuerta sin comprometer los pesos pre-entrenados de los expertos.
- En la tercera fase de refinamiento, se mantuvo el esquema de enrutamiento suave, pero se ejecutó una actualización estructural profunda al reemplazar los perceptrones tradicionales por bloques TabTransformer en cada experto [27]. Esta modificación integró mecanismos de autoatención, diseñados para capturar de forma más efectiva las relaciones latentes y las interacciones multivariadas complejas dentro de las características tabulares del tráfico de red. Los resultados obtenidos consolidaron la superioridad de la arquitectura MoE sobre la línea base comparativa, obteniendo un F1-Score Macro de 0.89 e incrementando drásticamente la Precisión Macro hasta un 0.96 con el uso de SMOTE-Tomek [16]. La ganancia sustancial en las métricas evidencia que los mecanismos de atención fueron determinantes para optimizar la reducción de

falsos positivos, validando al ensamble MoE con TabTransformers como la configuración más robusta para la detección de intrusiones en entornos de desbalance crítico [8], [29].

## Conclusiones

- Se considera que el desarrollo posee una alta pertinencia profesional debido a que la digitalización acelerada exige sistemas de defensa capaces de discriminar tráfico malicioso en infraestructuras críticas donde la proporción de intrusiones es estadísticamente mínima frente al tráfico benigno lo cual es requerido en sistemas a nivel nacional y global.
- Se concluyó que las estrategias de depuración de datos deben preservar el desbalance estructural original (eliminando duplicados y nulos exclusivamente de la clase mayoritaria) para evitar la introducción de sesgos artificiales que perjudiquen el entrenamiento en escenarios realistas para el caso de un dataset con desbalance extremo, como es el presente caso.
- Se reconoció que los modelos basados en árboles clasificadores permiten obtener un mejor reconocimiento de patrones de características a la hora de generar una clasificación adecuada de las intrusiones obteniendo métricas más altas en sus modelos base y mejorados con técnicas en comparación al uso de redes neuronales estándar para objetivos de identificación de intrusiones esto siendo que los modelos base de Random Forest y XGBoost generaron F1-scores macro de 0.85 y 0.83 mientras que el modelo de tipo red neuronal estándar de perceptrón multicapa solo llegó a un F1-score macro de 0.77

- Se validó que, ante escenarios de desbalance extremo, la asignación de penalizaciones mediante funciones de costo (como Balanced) resulta ser una técnica de regularización más estable y efectiva que la inyección de ruido sintético puro, la cual tiende a degradar las fronteras de decisión.
- Se determinó que la agrupación de intrusiones intra-dominio, como las diferentes variantes de ataques Web (Brute Force, SQL Injection, XSS), reduce sustancialmente la confusión del clasificador y eleva el F1-Score Macro hasta 0.93 en modelos base, debido al alto nivel de similitud en sus características de red.
- Se evidenció que las técnicas de reducción de dimensionalidad y selección de características (como F-ANOVA o árboles clasificadores) no aportan mejoras predictivas, concluyendo que la dimensionalidad original contiene firmas sutiles e indispensables para la detección de ataques minoritarios.
- Se implementó exitosamente una arquitectura de Inteligencia Artificial basada en Mixture of Experts (MoE) que superó las limitaciones de convergencia de las redes neuronales estándar y logró sobrepasar el rendimiento predictivo de clasificadores robustos como Random Forest en el tratamiento de datos tabulares.
- Se demostró empíricamente que la integración de bloques TabTransformer bajo un esquema de enrutamiento continuo incrementa la capacidad del modelo para capturar relaciones multivariadas complejas, logrando estabilizar el F1-Score Macro en 0.89 y maximizar la Precisión Macro hasta 0.96 lo cual mejora de manera significativa a las métricas obtenidas en el modelo base de tipo Random Forest.
- Se estableció que el uso de tasas de aprendizaje independientes y concurrentes para la red de enrutamiento y los expertos durante la fase de ajuste fino global (fine-tuning) es fundamental para lograr la sincronización del ensamble, evitando la degradación de las representaciones previamente adquiridas.



- Se validó que el mecanismo de Soft Gating es técnicamente superior al esquema de Hard Gating para la clasificación de intrusiones, ya que permite una colaboración ponderada entre expertos que mitiga el ruido predictivo en muestras con firmas de red solapadas. Mientras que el enrutamiento estricto descarta información probabilística crítica, el esquema basado en Softmax garantiza un consenso que eleva la capacidad de generalización del ensamble frente a ataques sofisticados
- Se determinó que la efectividad de la arquitectura MoE reside en una segmentación taxonómica de subconjuntos basada en la dificultad de distinción de las etiquetas y en la integración de modelos de expertos adaptados a la estructura del tráfico. En este contexto, la transición de perceptrones multicapa hacia bloques TabTransformer permitió explotar mecanismos de autoatención para capturar relaciones complejas entre clases, optimizando el F1-score macro en la detección de anomalías dentro de datos tabulares de red

### **Recomendaciones**

Con base en la metodología ejecutada y la validación empírica de los resultados en la clasificación de intrusiones cibernéticas, se establecen las siguientes recomendaciones de buenas prácticas para la replicabilidad y optimización de futuros proyectos e investigaciones de esta índole:

- Se recomienda mantener la distribución y el desbalance original del conjunto de datos. La eliminación de registros duplicados y la exclusión de nulos estructurales deben aplicarse exclusivamente sobre la clase mayoritaria (tráfico benigno), con el fin de evitar la alteración o pérdida de información representativa de los ataques minoritarios
- Es imperativo aplicar estrategias de imputación condicionadas a cada clase dado que en ciberseguridad los datos faltantes no son aleatorios, imputar variables de forma

generalizada alteraría y difuminaría el comportamiento específico de cada tipo de ataque.

- Se recomienda evitar técnicas de reducción de dimensionalidad que combinen variables, como el Análisis de Componentes Principales (PCA), ya que los resultados experimentales evidencian que la disminución de características degrada las métricas de clasificación. Este efecto, observado en la serie de experimentos 4, indica que conservar la mayoría o la totalidad de las características durante el entrenamiento mejora la discriminación de clases minoritarias al mantener un espacio de representación más completo [2].
- Para el manejo del desbalance extremo en el dataset de intrusiones, resulta una práctica más estable priorizar el uso de penalizaciones dinámicas en lugar del sobremuestreo sintético. La introducción excesiva de ruido sintético tiende a degradar las fronteras de decisión en modelos basados en árboles y redes neuronales
- Ante la alta dimensionalidad y el elevado costo computacional de los experimentos, se debe utilizar optimización bayesiana como Optuna en lugar de métodos de cuadrícula exhaustiva como Grid Search, permitiendo priorizar generación de modelos más prometedores y podar configuraciones ineficientes
- En el diseño de la compuerta integradora, se recomienda evitar el enrutamiento rígido (Hard Gating). En su lugar, el uso de capas Softmax para emitir probabilidades condicionales permite que la predicción final se beneficie de la ponderación simultánea de todos los expertos, lo cual es crítico frente a ataques con firmas solapadas
- La partición de los subconjuntos de datos para entrenar a cada experto no debe ser aleatoria ni estrictamente por volumen. Es una buena práctica analizar los errores (matrices de confusión) de los modelos de línea base para agrupar deliberadamente

clases que el modelo confunde entre sí (como tráfico benigno con ataques camuflados), forzando al experto a especializarse en distinguir esos patrones.

- Para procesar datos de tráfico de red, se recomienda prescindir de redes MLP tradicionales y dotar a los expertos de arquitecturas especializadas en tabularidad, como bloques TabTransformer. Esto asegura que cada subred pueda capturar interacciones latentes complejas, logrando optimizar las métricas de clasificación.

### **Trabajo Futuro**

Con base en lo desarrollado en el presente proyecto, donde se llevaron a cabo implementaciones de modelos base y arquitecturas de tipo Mixture of Experts (MoE) especializadas en la clasificación de distintos tipos de intrusiones, y respecto al alcance obtenido, se plantean los siguientes puntos como potencial trabajo futuro para continuar la línea de mejora continua de esta investigación:

- Implementación de arquitecturas de modelos base y de tipo Mixture of Experts sobre nuevos dataset de intrusiones cibernéticas para comprobar si el presente trabajo se puede extender a muestras recabadas y analizadas en otras investigaciones. A su vez, se plantea extender el dataset CIC-IDS2017 (de la Universidad de New Brunswick) empleado en este estudio, fusionándolo con otros conjuntos de datos mediante la homologación a nivel de features y labels. Todo esto con el objetivo de generalizar al máximo la arquitectura del modelo, con miras a su implementación en entornos reales para la detección de intrusiones en tiempo real.
- Generación de una API de consumo e implementación sobre un entorno o sitio web de Pentesting para validar, en situaciones de simulación de ataques, la capacidad de

respuesta del modelo de detección. La finalidad es utilizar el output generado para determinar y aplicar reglas dinámicas a nivel de capa de red y de aplicación, impidiendo el tráfico con características maliciosas. De esta forma, se busca validar la generalización y utilidad del modelo en un escenario operativo y realista.

- Validación de arquitecturas Mixture of Experts incorporando modelos de red neuronal y arquitecturas mixtas diferentes a nivel de los expertos. En el presente proyecto se emplearon arquitecturas basadas en Multilayer Perceptron (MLP) y TabTransformer; no obstante, es importante evaluar el rendimiento de enfoques como 1D-CNN o FT-Transformer. Esto permitirá valorar si poseen una mejor capacidad para modelar relaciones no lineales complejas, lo que podría traducirse en una mejora significativa del rendimiento global del sistema.
- Evaluación de la arquitectura sobre conjuntos de datos con ataques web agrupados, replicando la metodología explorada en los modelos base. Dado que el objetivo central de esta fase fue superar la línea base utilizando las etiquetas originales, surge como oportunidad el entrenamiento de MoEs estrictamente especializados en estas agrupaciones. Esto implicaría la readaptación del pipeline para volver a producir los datos y el entrenamiento de nuevos expertos específicos, con el fin de determinar si la agrupación potencia la precisión de la detección frente a ataques web complejos.
- En consideración de que a pesar de la complejidad de los modelos existió dificultad en potenciar las métricas de clasificación de los ataques de tipo Bot debido a que contienen firmas de características similares al tráfico benigno se considera que se debe ampliar la cantidad de muestras de intrusiones de tipo Bot en el dataset de entrenamiento para mejorar la detección de este tipo de ataque. Para este propósito se puede tomar como referencia el dataset de la investigación del IEEE “A review and analysis of the bot-iot dataset” de Peterson, Leevy y Khoshgoftaar [32]


## Referencias bibliográficas

1. P. Mishra, V. Varadharajan, U. Tupakula and E. S. Pilli, "A Detailed Investigation and Analysis of Using Machine Learning Techniques for Intrusion Detection," *IEEE Communications Surveys & Tutorials*, vol. 21, no. 1, pp. 686–728, Firstquarter 2019, doi: 10.1109/COMST.2018.2847722.
2. H. He and E. A. Garcia, "Learning from Imbalanced Data," in *Data Mining and Knowledge Discovery Handbook*, 2nd ed., O. Maimon and L. Rokach, Eds. Boston, MA, USA: Springer, 2020, pp. 875–896.
3. S. Raschka, *Model Evaluation, Model Selection, and Algorithm Selection in Python Machine Learning*, 3rd ed., Birmingham, UK: Packt Publishing, 2019.
4. A. Thakkar and R. Lohiya, "Fusion of statistical importance for feature selection in deep neural network-based intrusion detection system," *Information Fusion*, vol. 90, pp. 353–363, 2023, doi: 10.1016/j.inffus.2022.09.026.
5. U. K. Lilhore, S. Dalal, and S. Simaiya, "A cognitive security framework for detecting intrusions in IoT and 5G utilizing deep learning," *Computers & Security*, vol. 136, p. 103560, 2024, doi: 10.1016/j.cose.2023.103560.
6. H. Zhang, L. Huang, C. Q. Wu, and Z. Li, "An effective convolutional neural network based on SMOTE and Gaussian mixture model for intrusion detection in imbalanced dataset," *Computer Networks*, vol. 177, p. 107315, 2020, doi: 10.1016/j.comnet.2020.107315.
7. Y. Han et al., "Dynamic neural networks: A survey," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, no. 11, pp. 7436–7456, 2022, doi: 10.1109/TPAMI.2021.3117837.
8. L. Ilias, G. Doukas, V. Lamprou, C. Ntanos, and D. Askounis, "Convolutional neural networks and mixture of experts for intrusion detection in 5G networks and beyond," *Frontiers in Artificial Intelligence*, vol. 8, Art. no. 1708953, 2026, doi: 10.3389/frai.2025.1708953.
9. Canadian Institute for Cybersecurity, University of New Brunswick, CIC-IDS2017 Intrusion Detection Evaluation Dataset, Disponible en: <https://www.unb.ca/cic/datasets/ids-2017.html>
10. I. Sharafaldin et al., *Proc. 4th Int. Conf. Inf. Syst. Secur. Privacy*, 2018, pp. 108–116.
11. S. G. Liao, Y. Lin, D. D. Kang, D. Chandra, J. Bon, N. Kaminski, et al., "Missing value imputation in high-dimensional phenomic data: imputable or not, and how?," *BMC Bioinformatics*, vol. 15, no. 1, p. 346, 2014.
12. F. Hinder et al., *ACM Comput. Surv.*, vol. 56, no. 4, pp. 1–35, 2023.
13. M. Ring et al., *Comput. Secur.*, vol. 86, pp. 147–167, 2019.
14. S. García et al., *Data Preprocessing in Data Mining*, Springer, 2015.
15. Wu, K., Qu, H., and Huang, C., "A Network Intrusion Detection Method Incorporating Bayesian Attack Graph and Incremental Learning Part," *Future Internet*, vol. 15, no. 4, p. 128, 2023. doi: 10.3390/fi15040128.
16. D. Kasina, V. S. Reddy, S. Rajamanickam, J. Jose, and B. Palani, "A novel intrusion detection system for class imbalance datasets using hybrid sampling with deep learning techniques," *Information Sciences*, vol. 741, p. 123208, Jun. 2026. doi: 10.1016/j.ins.2026.123208.
17. J. M. Johnson and T. M. Khoshgoftaar, "Survey on deep learning with class imbalance," *J. Big Data*, vol. 6, no. 1, pp. 1–54, Dec. 2019. doi: 10.1186/s40537-019-0192-5.




18. T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A Next-generation Hyperparameter Optimization Framework," in Proc. 25th ACM SIGKDD Int. Conf. Knowl. Discov. Data Min., 2019, pp. 2623–2631.
19. P. V. Chavan and N. V. Alone, "Optimizing Intrusion Detection with Random Forest: A High-Accuracy Approach using CIC-IDS2017" International Journal of Computer Applications, vol. 187, no. 3, pp. 17–22, May 2025.
20. T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining (KDD), San Francisco, CA, USA, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.
21. T. H. Sow and M. Adda, "Enhancing IDS performance through a comparative analysis of Random Forest, XGBoost, and Deep Neural Networks," Machine Learning with Applications, vol. 22, Art. no. 100738, 2025, doi: 10.1016/j.mlwa.2025.100738.
22. R. Saini, G. Mussbacher, J. L. Guo y J. Kienzle, "Machine learning-based incremental learning in interactive domain modelling," en Proceedings of the 25th International Conference on Model Driven Engineering Languages and Systems, Oct. 2022, pp. 176–186.
23. A. Furlong, X. Zhao y R. Salko Jr., "Comparison of hybrid and pure machine learning models in limited data scenarios," Oak Ridge National Laboratory (ORNL), Oak Ridge, TN, USA, 2024
24. M. J. Siraj, T. Ahmad y R. M. Ijtihadie, "Analyzing ANOVA F-test and Sequential Feature Selection for Intrusion Detection Systems," International Journal of Advances in Soft Computing & Its Applications, vol. 14, no. 2, 2022.
25. M. Mulyanto, M. Faisal, S. W. Prakosa y J. S. Leu, "Effectiveness of focal loss for minority classification in network intrusion detection systems," Symmetry, vol. 13, no. 1, p. 4, 2020.
26. R. Singh, H. Kumar, R. K. Singla y R. R. Ketti, "Internet attacks and intrusion detection system: A review of the literature," Online Information Review, vol. 41, no. 2, pp. 171–184, 2017.
27. D. McElfresh, S. Khandagale, J. Valverde, V. Prasad C, G. Ramakrishnan, M. Goldblum y C. White, "When do neural nets outperform boosted trees on tabular data?," Advances in Neural Information Processing Systems, vol. 36, pp. 76336–76369, 2023.
28. J. Liu, P. Tang, W. Wang, Y. Ren, X. Hou, P. A. Heng, et al., "A survey on inference optimization techniques for mixture of experts models," ACM Computing Surveys, vol. 58, no. 10, pp. 1–37, 2026.
29. J. Wang, L. Nie, J. Duan, H. Zhao y C. P. Chen, "MFBLS: A Mixture-of-Experts-Based Fuzzy Broad Learning System for Tackling Imbalanced Datasets," IEEE Transactions on Fuzzy Systems, 2025.
30. Zhou, Y., Lei, T., Liu, H., Du, N., Huang, Y., Zhao, V., ... & Laudon, J. (2022). Mixture-of-experts with expert choice routing. Advances in Neural Information Processing Systems, 35, 7103-7114.
31. H. Nguyen, T. Nguyen y N. Ho, "Demystifying softmax gating function in Gaussian mixture of experts," Advances in Neural Information Processing Systems, vol. 36, pp. 4624–4652, 2023.
32. J. M. Peterson, J. L. Leevy y T. M. Khoshgoftaar, "A review and analysis of the Bot-IoT dataset," en Proc. IEEE Int. Conf. Service-Oriented System Engineering (SOSE), Aug. 2021, pp. 20–27, doi: 10.1109/SOSE52839.2021.00007




### Anexo A: Conteo Inicial de Muestras por Clase




|                          | count   | percent   |
|--------------------------|---------|-----------|
| label                    |         |           |
| BENIGN                   | 2273097 | 80.300366 |
| DoS Hulk                 | 231073  | 8.162981  |
| PortScan                 | 158930  | 5.614427  |
| DDoS                     | 128027  | 4.522735  |
| DoS GoldenEye            | 10293   | 0.363615  |
| FTP-Patator              | 7938    | 0.280421  |
| SSH-Patator              | 5897    | 0.208320  |
| DoS slowloris            | 5796    | 0.204752  |
| DoS Slowhttptest         | 5499    | 0.194260  |
| Bot                      | 1966    | 0.069452  |
| Web Attack Brute Force   | 1507    | 0.053237  |
| Web Attack XSS           | 652     | 0.023033  |
| Infiltration             | 36      | 0.001272  |
| Web Attack Sql Injection | 21      | 0.000742  |
| Heartbleed               | 11      | 0.000389  |

**Anexo B: Gráficos de Distribución de Features para tráfico Benigno y Ataques**














## Anexo C: Boxplots de Features por Clase para Flujos Benignos e Intrusiones







## Anexo D: Tabla de Resumen Antes de la Limpieza de Datos


|                             | tipo_datos | no_nulos | nulos | alores_unico | count   | mean       | std        | min        | 25%        | 50%        | 75%        | max        |
|-----------------------------|------------|----------|-------|--------------|---------|------------|------------|------------|------------|------------|------------|------------|
| flow_bytes/s                | float64    | 2829385  | 1358  | 1593908      | 2829385 | inf        |            | -261000000 | 119.319731 | 4595.54913 | 166666.667 | inf        |
| flow_duration               | int64      | 2830743  | 0     | 1050899      | 2830743 | 14785663.9 | 33653744.1 | -13        | 155        | 31316      | 3204828.5  | 1199999998 |
| destination_port            | int64      | 2830743  | 0     | 53805        | 2830743 | 8071.4825  | 18283.6322 | 0          | 53         | 80         | 443        | 65535      |
| total_backward_packets      | int64      | 2830743  | 0     | 1747         | 2830743 | 10.3937701 | 997.388269 | 0          | 1          | 2          | 4          | 291922     |
| total_length_of_fwd_packets | int64      | 2830743  | 0     | 17928        | 2830743 | 549.302415 | 9993.58923 | 0          | 12         | 62         | 187        | 12900000   |
| total_length_of_bwd_packets | int64      | 2830743  | 0     | 64698        | 2830743 | 16162.6425 | 2263088.05 | 0          | 0          | 123        | 482        | 655453030  |
| total_fwd_packets           | int64      | 2830743  | 0     | 1432         | 2830743 | 9.36115995 | 749.672792 | 1          | 2          | 2          | 5          | 219759     |
| fwd_packet_length_max       | int64      | 2830743  | 0     | 5279         | 2830743 | 207.599941 | 717.184842 | 0          | 6          | 37         | 81         | 24820      |
| fwd_packet_length_min       | int64      | 2830743  | 0     | 384          | 2830743 | 18.7136561 | 60.3393454 | 0          | 0          | 2          | 36         | 2325       |
| fwd_packet_length_std       | float64    | 2830743  | 0     | 253909       | 2830743 | 68.9101335 | 281.187092 | 0          | 0          | 0          | 26.1629509 | 7125.59685 |
| fwd_packet_length_mean      | float64    | 2830743  | 0     | 99716        | 2830743 | 58.2019385 | 186.091157 | 0          | 6          | 34         | 50         | 5940.85714 |
| bwd_packet_length_max       | int64      | 2830743  | 0     | 4838         | 2830743 | 870.849455 | 1946.36738 | 0          | 0          | 79         | 280        | 19530      |
| bwd_packet_length_min       | int64      | 2830743  | 0     | 583          | 2830743 | 41.0495792 | 68.8626026 | 0          | 0          | 0          | 77         | 2896       |
| bwd_packet_length_mean      | float64    | 2830743  | 0     | 147614       | 2830743 | 305.949281 | 605.2568   | 0          | 0          | 72         | 181        | 5800.5     |
| bwd_packet_length_std       | float64    | 2830743  | 0     | 248869       | 2830743 | 335.325721 | 839.693218 | 0          | 0          | 0          | 77.9405368 | 8194.66049 |
| flow_packets/s              | float64    | 2830743  | 0     | 1240164      | 2830743 | inf        |            | -2000000   | 3.44622571 | 110.668437 | 23255.814  | inf        |
| flow_iat_mean               | float64    | 2830743  | 0     | 1166311      | 2830743 | 1298448.71 | 4507944.17 | -13        | 63.6666667 | 11438.8421 | 337426.6   | 120000000  |
| flow_iat_std                | float64    | 2830743  | 0     | 1056642      | 2830743 | 2919270.92 | 8045869.78 | 0          | 0          | 137.178716 | 691266.282 | 84800261.6 |
| flow_iat_max                | int64      | 2830743  | 0     | 580289       | 2830743 | 9182475.32 | 24459539.3 | -13        | 123        | 30865      | 2440145    | 120000000  |
| flow_iat_min                | int64      | 2830743  | 0     | 136316       | 2830743 | 162379.562 | 2950281.78 | -14        | 3          | 4          | 64         | 120000000  |
| fwd_iat_total               | int64      | 2830743  | 0     | 493098       | 2830743 | 14482961.7 | 33575811.6 | 0          | 0          | 43         | 1242843.5  | 120000000  |
| fwd_iat_mean                | float64    | 2830743  | 0     | 737737       | 2830743 | 2610192.97 | 9525722.49 | 0          | 0          | 26         | 206306.358 | 120000000  |
| fwd_iat_std                 | float64    | 2830743  | 0     | 700313       | 2830743 | 3266957.22 | 9639055.4  | 0          | 0          | 0          | 65989.8217 | 84602929.3 |
| fwd_iat_max                 | int64      | 2830743  | 0     | 437316       | 2830743 | 9042938.56 | 24529157.4 | 0          | 0          | 43         | 931006     | 120000000  |
| fwd_iat_min                 | int64      | 2830743  | 0     | 110631       | 2830743 | 1021892.91 | 8591436.34 | -12        | 0          | 3          | 48         | 120000000  |
| bwd_iat_total               | int64      | 2830743  | 0     | 414928       | 2830743 | 9893830.35 | 28736614.2 | 0          | 0          | 3          | 98580.5    | 120000000  |
| bwd_iat_mean                | float64    | 2830743  | 0     | 670824       | 2830743 | 1805783.77 | 8887197.08 | 0          | 0          | 3          | 18248.5674 | 120000000  |
| bwd_iat_std                 | float64    | 2830743  | 0     | 709042       | 2830743 | 1485973.35 | 6278468.57 | 0          | 0          | 0          | 15724.093  | 84418013.8 |
| bwd_iat_max                 | int64      | 2830743  | 0     | 368285       | 2830743 | 4684692.43 | 17160950.1 | 0          | 0          | 3          | 60210      | 120000000  |
| bwd_iat_min                 | int64      | 2830743  | 0     | 66074        | 2830743 | 967261.371 | 8308983.09 | 0          | 0          | 1          | 45         | 120000000  |
| fwd_psh_flags               | int64      | 2830743  | 0     | 2            | 2830743 | 0.04644646 | 0.21045001 | 0          | 0          | 0          | 0          | 1          |
| bwd_psh_flags               | int64      | 2830743  | 0     | 1            | 2830743 | 0          | 0          | 0          | 0          | 0          | 0          | 0          |
| fwd_urg_flags               | int64      | 2830743  | 0     | 2            | 2830743 | 0.00011128 | 0.01054826 | 0          | 0          | 0          | 0          | 1          |
| bwd_urg_flags               | int64      | 2830743  | 0     | 1            | 2830743 | 0          | 0          | 0          | 0          | 0          | 0          | 0          |
| fwd_header_length           | int64      | 2830743  | 0     | 3771         | 2830743 | -25997.392 | 21052857.9 | -3.221E+10 | 40         | 64         | 120        | 4644908    |
| bwd_header_length           | int64      | 2830743  | 0     | 3945         | 2830743 | -2273.2753 | 1452208.94 | -1.074E+09 | 20         | 40         | 104        | 5838440    |
| fwd_packets/s               | float64    | 2830743  | 0     | 1220423      | 2830743 | 63865.3464 | 247537.13  | 0          | 1.74944645 | 61.3252384 | 12048.1928 | 3000000    |
| bwd_packets/s               | float64    | 2830743  | 0     | 1107886      | 2830743 | 6995.19174 | 38151.6977 | 0          | 0.12291971 | 19.8278939 | 7352.94118 | 2000000    |
| min_packet_length           | int64      | 2830743  | 0     | 215          | 2830743 | 16.4345047 | 25.2377208 | 0          | 0          | 2          | 36         | 1448       |
| max_packet_length           | int64      | 2830743  | 0     | 5708         | 2830743 | 950.402445 | 2028.22915 | 0          | 6          | 87         | 525        | 24820      |
| packet_length_mean          | float64    | 2830743  | 0     | 215826       | 2830743 | 171.94439  | 305.491461 | 0          | 6          | 57.2       | 119.8      | 3337.14286 |
| packet_length_std           | float64    | 2830743  | 0     | 412246       | 2830743 | 294.975554 | 631.800073 | 0          | 0          | 25.9807621 | 174.323949 | 4731.52239 |
| packet_length_variance      | float64    | 2830743  | 0     | 405565       | 2830743 | 486154.794 | 1647489.87 | 0          | 0          | 675        | 30388.8393 | 22400000   |
| fin_flag_count              | int64      | 2830743  | 0     | 2            | 2830743 | 0.03537976 | 0.18473777 | 0          | 0          | 0          | 0          | 1          |
| syn_flag_count              | int64      | 2830743  | 0     | 2            | 2830743 | 0.04644646 | 0.21045001 | 0          | 0          | 0          | 0          | 1          |
| rst_flag_count              | int64      | 2830743  | 0     | 2            | 2830743 | 0.00024234 | 0.01556536 | 0          | 0          | 0          | 0          | 1          |
| psh_flag_count              | int64      | 2830743  | 0     | 2            | 2830743 | 0.29807051 | 0.45741071 | 0          | 0          | 0          | 0          | 1          |
| ack_flag_count              | int64      | 2830743  | 0     | 2            | 2830743 | 0.31584429 | 0.46485132 | 0          | 0          | 0          | 0          | 1          |
| urg_flag_count              | int64      | 2830743  | 0     | 2            | 2830743 | 0.09482316 | 0.29297058 | 0          | 0          | 0          | 0          | 1          |
| cwe_flag_count              | int64      | 2830743  | 0     | 2            | 2830743 | 0.00011128 | 0.01054826 | 0          | 0          | 0          | 0          | 1          |
| ece_flag_count              | int64      | 2830743  | 0     | 2            | 2830743 | 0.0002434  | 0.01559935 | 0          | 0          | 0          | 0          | 1          |
| down/up_ratio               | int64      | 2830743  | 0     | 31           | 2830743 | 0.68350041 | 0.68049199 | 0          | 0          | 1          | 1          | 156        |
| average_packet_size         | float64    | 2830743  | 0     | 212207       | 2830743 | 191.983658 | 331.860349 | 0          | 7.5        | 72.25      | 149.263932 | 3893.33333 |
| avg_fwd_segment_size        | float64    | 2830743  | 0     | 99716        | 2830743 | 58.2019385 | 186.091157 | 0          | 6          | 34         | 50         | 5940.85714 |
| avg_bwd_segment_size        | float64    | 2830743  | 0     | 147611       | 2830743 | 305.949281 | 605.2568   | 0          | 0          | 72         | 181        | 5800.5     |
| fwd_header_length.1         | int64      | 2830743  | 0     | 3771         | 2830743 | -25997.392 | 21052857.9 | -3.221E+10 | 40         | 64         | 120        | 4644908    |
| fwd_avg_bytes/bulk          | int64      | 2830743  | 0     | 1            | 2830743 | 0          | 0          | 0          | 0          | 0          | 0          | 0          |
| fwd_avg_packets/bulk        | int64      | 2830743  | 0     | 1            | 2830743 | 0          | 0          | 0          | 0          | 0          | 0          | 0          |
| fwd_avg_bulk_rate           | int64      | 2830743  | 0     | 1            | 2830743 | 0          | 0          | 0          | 0          | 0          | 0          | 0          |
| bwd_avg_bytes/bulk          | int64      | 2830743  | 0     | 1            | 2830743 | 0          | 0          | 0          | 0          | 0          | 0          | 0          |
| bwd_avg_packets/bulk        | int64      | 2830743  | 0     | 1            | 2830743 | 0          | 0          | 0          | 0          | 0          | 0          | 0          |
| bwd_avg_bulk_rate           | int64      | 2830743  | 0     | 1            | 2830743 | 0          | 0          | 0          | 0          | 0          | 0          | 0          |
| subflow_fwd_packets         | int64      | 2830743  | 0     | 1432         | 2830743 | 9.36115995 | 749.672792 | 1          | 2          | 2          | 5          | 219759     |
| subflow_fwd_bytes           | int64      | 2830743  | 0     | 17928        | 2830743 | 549.291936 | 9980.07024 | 0          | 12         | 62         | 187        | 12870338   |
| subflow_bwd_packets         | int64      | 2830743  | 0     | 1747         | 2830743 | 10.3937701 | 997.388269 | 0          | 1          | 2          | 4          | 291922     |
| subflow_bwd_bytes           | int64      | 2830743  | 0     | 64738        | 2830743 | 16162.3025 | 2263057.28 | 0          | 0          | 123        | 482        | 655453030  |
| init_win_bytes_forward      | int64      | 2830743  | 0     | 12151        | 2830743 | 6989.83745 | 14338.7258 | -1         | -1         | 251        | 8192       | 65535      |
| init_win_bytes_backward     | int64      | 2830743  | 0     | 13112        | 2830743 | 1989.43298 | 8456.88316 | -1         | -1         | -1         | 235        | 65535      |
| act_data_pkt_fwd            | int64      | 2830743  | 0     | 1093         | 2830743 | 5.41821776 | 636.425664 | 0          | 0          | 1          | 2          | 213557     |
| min_seg_size_forward        | int64      | 2830743  | 0     | 28           | 2830743 | -2741.6879 | 1084989.38 | -536870661 | 20         | 24         | 32         | 138        |
| active_mean                 | float64    | 2830743  | 0     | 326325       | 2830743 | 81551.321  | 648599.937 | 0          | 0          | 0          | 0          | 110000000  |
| active_std                  | float64    | 2830743  | 0     | 202826       | 2830743 | 41134.1168 | 393381.515 | 0          | 0          | 0          | 0          | 74200000   |
| active_max                  | float64    | 2830743  | 0     | 299565       | 2830743 | 153182.521 | 1025824.97 | 0          | 0          | 0          | 0          | 110000000  |
| active_min                  | int64      | 2830743  | 0     | 175670       | 2830743 | 58295.8177 | 577092.282 | 0          | 0          | 0          | 0          | 110000000  |
| idle_mean                   | float64    | 2830743  | 0     | 222016       | 2830743 | 8316036.63 | 23630078.6 | 0          | 0          | 0          | 0          | 120000000  |
| idle_std                    | float64    | 2830743  | 0     | 197616       | 2830743 | 503843.95  | 4602984.48 | 0          | 0          | 0          | 0          | 76900000   |
| idle_max                    | int64      | 2830743  | 0     | 149737       | 2830743 | 8695751.98 | 24366888.3 | 0          | 0          | 0          | 0          | 120000000  |
| idle_min                    | int64      | 2830743  | 0     | 223888       | 2830743 | 7920031.01 | 23363418.9 | 0          | 0          | 0          | 0          | 120000000  |


## Anexo E: Tabla de Resumen Después de la Limpieza de Datos

|                             | tipo_dato | no_nulos | nulos | valores_unicos | count   | mean        | std         | min         | 25%         | 50%         | 75%         | max         |
|-----------------------------|-----------|----------|-------|----------------|---------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
| flow_bytes/s                | float64   | 2603842  | 949   | 1591480        | 2603842 | 9845832.739 | 745.152184  | 0           | 115.6653062 | 3778.272603 | 122448.9796 | inf         |
| flow_iat_min                | float64   | 2604597  | 194   | 136297         | 2604597 | 162225.1773 | 2940169.989 | 0           | 3           | 4           | 63          | 120000000   |
| fwd_iat_min                 | float64   | 2604774  | 17    | 110603         | 2604774 | 1096493.297 | 8906803.163 | 0           | 0           | 3           | 48          | 120000000   |
| destination_port            | int64     | 2604791  | 0     | 53800          | 2604791 | 8526.501771 | 18742.97417 | 0           | 53          | 80          | 443         | 65535       |
| total_backward_packets      | int64     | 2604791  | 0     | 1393           | 2604791 | 5.957699869 | 107.2735587 | 0           | 1           | 2           | 5           | 157388      |
| total_fwd_packets           | int64     | 2604791  | 0     | 1105           | 2604791 | 6.051365349 | 77.54137362 | 1           | 1           | 2           | 5           | 112141      |
| flow_duration               | int64     | 2604791  | 0     | 1048660        | 2604791 | 15995932.78 | 34725769.72 | 0           | 185         | 48104       | 5138656.5   | 119999998   |
| total_length_of_fwd_packets | int64     | 2604791  | 0     | 17557          | 2604791 | 568.3856025 | 9551.830143 | 0           | 12          | 64          | 318         | 12900000    |
| fwd_packet_length_mean      | float64   | 2604791  | 0     | 98332          | 2604791 | 61.48461334 | 193.2673342 | 0           | 6           | 35          | 51.33333333 | 5940.857143 |
| fwd_packet_length_std       | float64   | 2604791  | 0     | 251966         | 2604791 | 74.61357609 | 292.1033677 | 0           | 0           | 0           | 69.5139874  | 7125.596846 |
| fwd_packet_length_max       | int64     | 2604791  | 0     | 5263           | 2604791 | 223.0643622 | 744.186387  | 0           | 6           | 38          | 196         | 24820       |
| total_length_of_bwd_packets | int64     | 2604791  | 0     | 63305          | 2604791 | 5807.307348 | 261090.1515 | 0           | 6           | 142         | 796         | 399000000   |
| bwd_packet_length_min       | int64     | 2604791  | 0     | 581            | 2604791 | 41.91369365 | 70.06944837 | 0           | 0           | 0           | 79          | 2896        |
| bwd_packet_length_max       | int64     | 2604791  | 0     | 4811           | 2604791 | 940.4843225 | 2010.296467 | 0           | 6           | 91          | 509         | 19530       |
| bwd_packet_length_std       | float64   | 2604791  | 0     | 246864         | 2604791 | 363.7240736 | 869.2267494 | 0           | 0           | 0           | 199.1030476 | 8194.660487 |
| bwd_packet_length_mean      | float64   | 2604791  | 0     | 145861         | 2604791 | 328.5842979 | 624.1309329 | 0           | 6           | 82          | 207         | 5800.5      |
| flow_packets/s              | float64   | 2604791  | 0     | 1237758        | 2604791 | 9946834.739 | 25321845.02 | 0.016701329 | 2.402734529 | 82.43173622 | 20618.5567  | 253218459   |
| flow_iat_mean               | float64   | 2604791  | 0     | 1163904        | 2604791 | 1396267.17  | 4598706.031 | 0           | 72          | 17024.33333 | 466401.4203 | 120000000   |
| flow_iat_std                | float64   | 2604791  | 0     | 1054261        | 2604791 | 3170350.382 | 8339486.683 | 0           | 0           | 7957.340573 | 1353140.203 | 84800261.57 |
| fwd_packet_length_min       | int64     | 2604791  | 0     | 384            | 2604791 | 18.7293852  | 62.41899708 | 0           | 0           | 2           | 36          | 2325        |
| flow_iat_max                | int64     | 2604791  | 0     | 579532         | 2604791 | 9946833.739 | 25321845.02 | 0           | 149         | 36610       | 4788586.5   | 120000000   |
| fwd_iat_total               | int64     | 2604791  | 0     | 492151         | 2604791 | 15668699.28 | 34655976.73 | 0           | 0           | 48          | 3992909     | 120000000   |
| fwd_iat_std                 | float64   | 2604791  | 0     | 698015         | 2604791 | 3547367.369 | 9997821.486 | 0           | 0           | 0           | 197651.8639 | 84602929.28 |
| fwd_iat_mean                | float64   | 2604791  | 0     | 735381         | 2604791 | 2821435.82  | 9860586.622 | 0           | 0           | 48          | 648890.4375 | 120000000   |
| fwd_iat_max                 | int64     | 2604791  | 0     | 436530         | 2604791 | 9796286.229 | 25399757.22 | 0           | 0           | 48          | 3178825     | 120000000   |
| bwd_iat_total               | int64     | 2604791  | 0     | 414111         | 2604791 | 1069378.18  | 29730160.04 | 0           | 0           | 3           | 145648      | 120000000   |
| bwd_iat_mean                | float64   | 2604791  | 0     | 668529         | 2604791 | 1961408.183 | 9247960.85  | 0           | 0           | 3           | 27629.375   | 120000000   |
| bwd_iat_std                 | float64   | 2604791  | 0     | 706761         | 2604791 | 1612365.541 | 6527915.01  | 0           | 0           | 0           | 23530.56862 | 84418013.78 |
| bwd_iat_max                 | int64     | 2604791  | 0     | 367533         | 2604791 | 5075318.837 | 17815912.85 | 0           | 0           | 3           | 96672       | 120000000   |
| bwd_iat_min                 | int64     | 2604791  | 0     | 66036          | 2604791 | 1051144.242 | 8656775.688 | 0           | 0           | 2           | 46          | 120000000   |
| fwd_psh_flags               | int64     | 2604791  | 0     | 2              | 2604791 | 0.046268587 | 0.210066233 | 0           | 0           | 0           | 0           | 1           |
| fwd_urg_flags               | int64     | 2604791  | 0     | 2              | 2604791 | 3.07126E-05 | 0.005541814 | 0           | 0           | 0           | 0           | 1           |
| fwd_header_length           | int64     | 2604791  | 0     | 3234           | 2604791 | 159.8149318 | 1678.902568 | 0           | 40          | 64          | 136         | 2289684     |
| bwd_header_length           | int64     | 2604791  | 0     | 3448           | 2604791 | 157.5571549 | 2207.145118 | 0           | 20          | 40          | 112         | 3147772     |
| fwd_packets/s               | float64   | 2604791  | 0     | 1218030        | 2604791 | 54073.62999 | 231665.8913 | 0           | 1.365409348 | 41.78854994 | 10416.66667 | 3000000     |
| bwd_packets/s               | float64   | 2604791  | 0     | 1105498        | 2604791 | 6694.291491 | 36215.54331 | 0           | 0.166154689 | 20.34919214 | 5571.030641 | 2000000     |
| min_packet_length           | int64     | 2604791  | 0     | 215            | 2604791 | 16.26728286 | 25.37304813 | 0           | 0           | 2           | 36          | 1448        |
| max_packet_length           | int64     | 2604791  | 0     | 5692           | 2604791 | 1026.292147 | 2093.371519 | 0           | 6           | 98          | 911         | 24820       |
| packet_length_mean          | float64   | 2604791  | 0     | 213984         | 2604791 | 183.8673911 | 314.4163342 | 0           | 6           | 61.33333333 | 140.5952381 | 3337.142857 |
| packet_length_std           | float64   | 2604791  | 0     | 410117         | 2604791 | 318.855353  | 652.4892615 | 0           | 2.309401077 | 30.67246322 | 278.7364048 | 4731.522394 |
| packet_length_variance      | float64   | 2604791  | 0     | 403439         | 2604791 | 527381.4789 | 1710754.566 | 0           | 5.333333333 | 940.8       | 77693.98333 | 22400000    |
| fin_flag_count              | int64     | 2604791  | 0     | 2              | 2604791 | 0.030957186 | 0.173201762 | 0           | 0           | 0           | 0           | 1           |
| syn_flag_count              | int64     | 2604791  | 0     | 2              | 2604791 | 0.046268587 | 0.210066233 | 0           | 0           | 0           | 0           | 1           |
| rst_flag_count              | int64     | 2604791  | 0     | 2              | 2604791 | 0.000261057 | 0.016155165 | 0           | 0           | 0           | 0           | 1           |
| psh_flag_count              | int64     | 2604791  | 0     | 2              | 2604791 | 0.313381381 | 0.463868056 | 0           | 0           | 0           | 1           | 1           |
| ack_flag_count              | int64     | 2604791  | 0     | 2              | 2604791 | 0.308747228 | 0.461976687 | 0           | 0           | 0           | 1           | 1           |
| urg_flag_count              | int64     | 2604791  | 0     | 2              | 2604791 | 0.09625993  | 0.294947435 | 0           | 0           | 0           | 0           | 1           |
| cwe_flag_count              | int64     | 2604791  | 0     | 2              | 2604791 | 3.07126E-05 | 0.005541814 | 0           | 0           | 0           | 0           | 1           |
| ece_flag_count              | int64     | 2604791  | 0     | 2              | 2604791 | 0.000262209 | 0.016190753 | 0           | 0           | 0           | 0           | 1           |
| down/up_ratio               | int64     | 2604791  | 0     | 31             | 2604791 | 0.6999456   | 0.688513471 | 0           | 0           | 1           | 1           | 156         |
| average_packet_size         | float64   | 2604791  | 0     | 210376         | 2604791 | 204.9834611 | 341.6561271 | 0           | 8           | 77.5        | 167.25      | 3893.333333 |
| avg_fwd_segment_size        | float64   | 2604791  | 0     | 98332          | 2604791 | 61.48461334 | 193.2673342 | 0           | 6           | 35          | 51.33333333 | 5940.857143 |
| avg_bwd_segment_size        | float64   | 2604791  | 0     | 145859         | 2604791 | 328.5842979 | 624.1309329 | 0           | 6           | 82          | 207         | 5800.5      |
| subflow_fwd_packets         | int64     | 2604791  | 0     | 1105           | 2604791 | 6.051365349 | 77.54137362 | 1           | 1           | 2           | 5           | 112141      |
| subflow_fwd_bytes           | int64     | 2604791  | 0     | 17557          | 2604791 | 568.3742151 | 9536.457034 | 0           | 12          | 64          | 318         | 12870338    |
| subflow_bwd_packets         | int64     | 2604791  | 0     | 1393           | 2604791 | 5.957699869 | 107.2735587 | 0           | 1           | 2           | 5           | 157388      |
| subflow_bwd_bytes           | int64     | 2604791  | 0     | 63310          | 2604791 | 5807.401864 | 261303.5323 | 0           | 6           | 142         | 796         | 399368696   |
| act_data_pkt_fwd            | int64     | 2604791  | 0     | 854            | 2604791 | 3.037578447 | 70.8564372  | 0           | 0           | 1           | 3           | 108273      |
| min_seg_size_forward        | int64     | 2604791  | 0     | 24             | 2604791 | 26.20990782 | 6.63719822  | 0           | 20          | 24          | 32          | 138         |
| active_mean                 | float64   | 2604791  | 0     | 324832         | 2604791 | 87361.64316 | 656056.085  | 0           | 0           | 0           | 0           | 110000000   |
| active_std                  | float64   | 2604791  | 0     | 201671         | 2604791 | 44136.62387 | 403634.2644 | 0           | 0           | 0           | 0           | 74200000    |
| active_max                  | int64     | 2604791  | 0     | 298199         | 2604791 | 164293.9029 | 1049098.096 | 0           | 0           | 0           | 0           | 110000000   |
| active_min                  | int64     | 2604791  | 0     | 175036         | 2604791 | 62407.22645 | 581701.8876 | 0           | 0           | 0           | 0           | 110000000   |
| idle_mean                   | float64   | 2604791  | 0     | 221303         | 2604791 | 9020411.551 | 24490869.29 | 0           | 0           | 0           | 0           | 120000000   |
| idle_std                    | float64   | 2604791  | 0     | 196506         | 2604791 | 546530.9655 | 4793361.751 | 0           | 0           | 0           | 0           | 76900000    |
| idle_max                    | int64     | 2604791  | 0     | 149411         | 2604791 | 9432290.31  | 25250536.78 | 0           | 0           | 0           | 0           | 120000000   |
| idle_min                    | int64     | 2604791  | 0     | 223244         | 2604791 | 8591013.959 | 24223850.74 | 0           | 0           | 0           | 0           | 120000000   |



## Anexo F: Distribuciones por característica antes y después de imputaciones por regresores bayesianos y de tipo árbol de decisión





## Anexo G: Matrices de Confusión de Modelos Base


**Descripción de Labels de la Matriz:** Tráfico Benigno: 0, Ataque Bot: 1, DDoS: 2, DoS

GoldenEye: 3, DoS Hulk: 4, DoS Slowhttptest: 5, DoS Slowloris: 6, FTP- Patator: 7,

Heartbleed: 8, Infiltration: 9, PortScan: 10, SSH- Patator: 11, Web Attack- Brute Force: 12,

Web Attack- SQL Injection: 13, Web Attack- XSS: 14

### Random Forest



**Detalle de Matriz:** La matriz indica a nivel de filas los valores reales y a nivel de columnas valores predichos. Por ende, se presentan cantidad de predicciones respecto a valores reales


**Primera Columna:** Falsos Negativos

**Primera Fila:** Falsos Positivos

**Diagonal:** Predicciones Correctas

**Casillas Restantes:** Predicciones Incorrectas

## XGBoost



**Detalle de Matriz:** La matriz indica a nivel de filas los valores reales y a nivel de columnas valores predichos. Por ende, se presentan cantidad de predicciones respecto a valores reales


**Primera Columna:** Falsos Negativos

**Primera Fila:** Falsos Positivos

**Diagonal:** Predicciones Correctas

**Casillas Restantes:** Predicciones Incorrectas

## Redes Neuronales tipo Perceptrón Multicapa



**Detalle de Matriz:** La matriz indica a nivel de filas los valores reales y a nivel de columnas valores predichos. Por ende, se presentan cantidad de predicciones respecto a valores reales

**Primera Columna:** Falsos Negativos

**Primera Fila:** Falsos Positivos

**Diagonal:** Predicciones Correctas

**Casillas Restantes:** Predicciones Incorrectas

## Anexo H. Matrices de Confusión de Arquitecturas Mixture of Experts


**Descripción de Labels de la Matriz:** Tráfico Benigno: 0, Ataque Bot: 1, DDoS: 2, DoS

GoldenEye: 3, DoS Hulk: 4, DoS Slowhttptest: 5, DoS Slowloris: 6, FTP- Patator: 7,

Heartbleed: 8, Infiltration: 9, PortScan: 10, SSH- Patator: 11, Web Attack- Brute Force: 12,

Web Attack- SQL Injection: 13, Web Attack- XSS: 14

### Matriz de Confusión- Primera Arquitectura:



**Detalle de Matriz:** La matriz indica a nivel de filas los valores reales y a nivel de columnas valores predichos. Por ende, se presentan cantidad de predicciones respecto a valores reales


**Primera Columna:** Falsos Negativos

**Primera Fila:** Falsos Positivos

**Diagonal:** Predicciones Correctas

**Casillas Restantes:** Predicciones Incorrectas

**Matriz de Confusión- Segunda Arquitectura:**



**Detalle de Matriz:** La matriz indica a nivel de filas los valores reales y a nivel de columnas valores predichos. Por ende, se presentan cantidad de predicciones respecto a valores reales

**Primera Columna:** Falsos Negativos

**Primera Fila:** Falsos Positivos

**Diagonal:** Predicciones Correctas

**Casillas Restantes:** Predicciones Incorrectas

### Matriz de Confusión- Tercera Arquitectura:



**Detalle de Matriz:** La matriz indica a nivel de filas los valores reales y a nivel de columnas valores predichos. Por ende, se presentan cantidad de predicciones respecto a valores reales

**Primera Columna:** Falsos Negativos

**Primera Fila:** Falsos Positivos

**Diagonal:** Predicciones Correctas

**Casillas Restantes:** Predicciones Incorrectas