COLEGIO DE CIENCIAS E INGENIERÍAS

INGENIERÍA EN CIENCIAS DE LA COMPUTACIÓN

Entregable 2 del Proyecto Integrador

Tutor: Ricardo Flores Moyano

Autor: John Ochoa Abad

Quito – Ecuador

2026

1. **Título del Proyecto:**

   Arquitectura Mixture of Experts para Clasificación de Ataques en Datasets con Desbalance Extremo de Clases

2. **Resumen de actividades realizadas:**

- **Revisión del estado del arte:** Se llevó a cabo una revisión extra del estado del arte orientada a definir cuáles son los modelos estándar que se utilizan en investigaciones modernas para la clasificación de intrusiones a manera de emplear dichos algoritmos para la generación de los modelos base del proyecto. Para dicho propósito se seleccionaron los modelos de tipo Random Forest, XGBoost y Redes Neuronales
- **Organización del repositorio:** Se generó una subida a Github de todos los desarrollos llevados a cabo hasta el momento junto a los logs respectivos de los experimentos por cada uno de los algoritmos de los modelos base. La última versión del proyecto se puede verificar en: https://github.com/johnnyredwood/ArquitecturaMoEClasificacionIntrusiones
- **Partición de dataset en entrenamiento, validación y test:** Se generó la partición estratificada del dataset procesado en sets de entrenamiento, validación y test con proporciones iguales a 70%, 15% y 15%
- **Encoding de Labels:** Para propósitos del entrenamiento de los modelo se llevó a cabo el encoding de los labels relacionados con cada uno de los tipos de intrusiones
- **Estandarización:** Se llevó a cabo con uso de Standard Scaler la estandarización de los datos para favorecer la convergencia de los modelos
- **Imputación por clase:** Se llevó a cabo la implementación de métodos supervisados de imputación por clase de tipo Bayesian Regressor y Random Forest Regressor para llenar los datos faltantes de tipo NaN. Posteriormente se evaluó los cambios en la media y en la distribución para seleccionar el modelo que mejor mantenía la distribución. En este caso fue el Bayesian Regressor
- **Estudio de funciones de ponderación de pesos:** Se definieron funciones de ponderaciones de pesos de tipo balanced, polinomial, log-ratio, effective samples y cost sensitive debido a su uso en algoritmos de clasificación para datasets desbalanceados y para cada función se realizaron los análisis de los pesos generados y posteriormente se implementaron dichas funciones como parte de los experimentos de los modelos
- **Sobremuestreo:** Se implementaron funciones de tipo SMOTE, SMOTE-ENN y SMOTE Tomek para generar el sobremuestreo de los datos de entrenamiento a manera de amplificar la cantidad de muestras en clases minoritarias. A la vez se generó un script para el respectivo análisis de artefactos a manera de identificar la generación de datos duplicados o redundantes.

- **Implementación de Feature Selector:** Se genero una función para la selección de características mediante dos métodos supervisados estadístico F y uso de árboles para identificación de características que aportan más información. Se implementó esto como parte del pipeline de los experimentos
- **Generación de scripts estáticos para documentación de logs:** Para el registro de los logs por cada uno de los experimentos se generaron scripts que permiten registrar a nivel de archivo .log las métricas obtenidas por clase y macro por cada experimento (f1-score, precisión, recall). A su vez, se generaron matrices de confusión por clase para cada experimento para documentar de mejor manera la clasificación a nivel de falsos negativos.
- **Experimentación con modelo de tipo Random Forest:** Se generaron una serie de experimentos con organización por bloques bajo el modelo Random Forest para validar en primer lugar el modelo base sin ninguna técnica y posteriormente evaluar de manera independiente el posible aporte del uso de sobremuestreo, funciones de pesos dinámicos, selección de características y finalmente evaluar el conjunto de las mejores técnicas encontradas junto al modelo base. A la vez, se ejecutó un experimento para evaluar el impacto de la agrupación de clases de ataques Web.
- **Experimentación con modelo de tipo XGBoost:** Se generaron una serie de experimentos con organización por bloques bajo el modelo XGBoost para validar en primer lugar el modelo base sin ninguna técnica y posteriormente evaluar de manera independiente el posible aporte del uso de sobremuestreo, funciones de pesos dinámicos, selección de características, funciones de pérdida y finalmente evaluar el conjunto de las mejores técnicas encontradas junto al modelo base. A la vez, se ejecutó un experimento para evaluar el impacto de la agrupación de clases de ataques Web.
- **Experimentación con modelo de tipo Red Neuronal:** Se generaron una serie de experimentos con organización por bloques bajo el modelo de Redes Neuronales tipo MLP y ResNet para validar en primer lugar el modelo base sin ninguna técnica y posteriormente evaluar de manera independiente el posible aporte del uso de sobremuestreo, funciones de pesos dinámicos, selección de características, funciones de pérdida y finalmente evaluar el conjunto de las mejores técnicas encontradas junto al modelo base. A la vez, se ejecutó un experimento para evaluar el impacto de la agrupación de clases de ataques Web.

3. Secciones o capítulos del documento final desarrollados

1. Desarrollo: Segunda Parte: Modelos Base
2. Referencias bibliográficas
3. Anexos

4. Revisión y firma del tutor del proyecto

Yo, Ricardo Flores Moyano, profesor de la carrera de Ingeniería en Ciencias de la Computación, hago constar que he revisado y, por lo tanto, apruebo las actividades realizadas durante este período de trabajo. Por otra parte, considero que el avance del proyecto integrador es adecuado y se corresponde con el cronograma definido en el documento de planificación.

Fdo: Ricardo Flores Moyano

Quito, 27 de Marzo de 2026